MODELSKA ANALIZA 1

06: LUŠČENJE MODELSKIH PARAMETROV IN RAZDELČNI MODELI

GAL ZAJC: 28242041

FMF, 2024/2025

UVOD

Ukvarjamo se z luščenjem modelskih parametrov (s fitanjem). Dobro merilo za odstopanje modela od meritev je $\boxed{\chi^2 = \sum_{i=1}^{N} \frac{(y_i - y(x_i, \boldsymbol{a}))^2}{\sigma_i^2}}$. Cilj je poiskati modelske parametre $\boldsymbol{a}$, ki minimizirajo χ^2. Minimizacijo lahko izvajamo, kot v domači nalogi o numerični minimizaciji, lahko pa uporabimo ukaz *NonlinearModelFit*. Posebno lep primer je $\boxed{f(x, \boldsymbol{a}) = \sum_{i=1}^{N} a_i f_i(x)}$. Tega bolje rešuje *LinearModelFit.* Ta rešuje sistem

$\boldsymbol{A.a} == \boldsymbol{b}$; $\quad A_{i,j} = \sum_{k=1}^{N} \frac{f_i(x_k) f_j(x_k)}{\sigma_k^2}$; $\quad b_i = \frac{\sum_{j=1}^{N} y_j f_i(x_j)}{\sigma_j^2}$.

1.) ODZIV TKIVA NA REAGENT

OSNOVNO

Obravnavamo vezavo reagenta X na receptor Y, v tkivu. Za reakcijo $X + Y \leftrightarrow Y^*$ velja $[Y] = \frac{y_0[X]}{[X]+a}$, kar pišemo tudi $\boxed{y = \frac{y_0\, x}{x+a} = \frac{y_0}{1+\frac{a}{x}}}$. To lahko lineariziramo kot $\boxed{y(x) = a\,x + b;\quad y = \frac{1}{y},\ x = \frac{1}{x};\ a = \frac{a}{y_0};\quad b = \frac{1}{y_0}}$. Majhne negotovosti se tako transformirajo kot $\left|\frac{d}{dy}\frac{1}{y}\right| \Delta y = \frac{1}{y^2}\,\Delta y$.

Najprej poglejmo funkcijo χ^2, ki jo minimiziramo

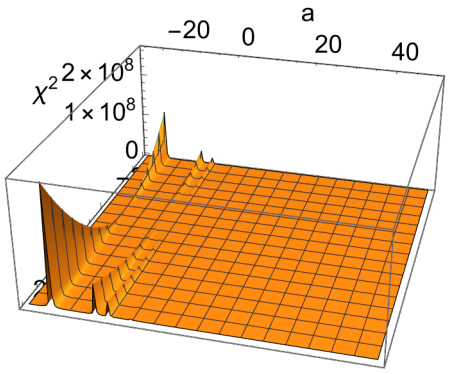

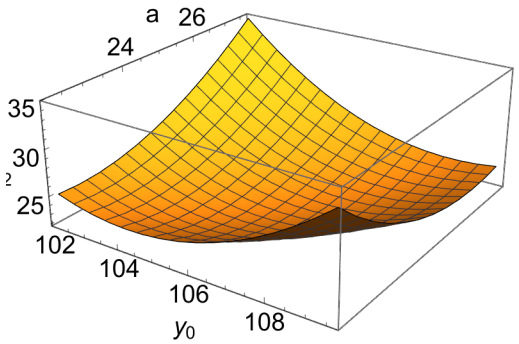

$\chi^2(y_0, a)$ in njena povečava okoli globalnega minimuma

Vidimo, da izgleda kar zanimivo, okoli lokalnega minimuma pa, kot bi pričakovali.

S prileganje grafa $\frac{x\,y0}{a+x}$ na meritve dobimo vrednosti parametrov:

- $y0 = 1.06 \times 10^2 \pm 2.$
- $a = 2.5 \times 10^1 \pm 2.$
- $\frac{\chi^2}{N-M} = 3.67$

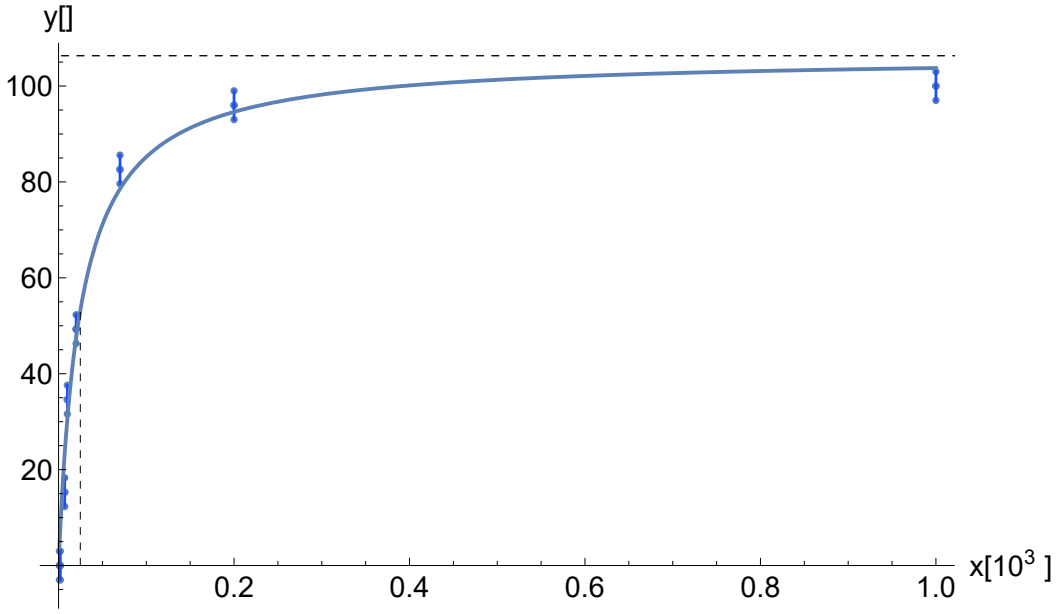

Farmakološke meritve in prilegani model

LINEARIZACIJA

Pri linearizirani verziji vidimo, da so napake majhnih meritev izredno velike, zato posebej prikažemo povečavo meritev brez 3 najbolj na desni

S prileganje grafa $b + a\,x$ na meritve dobimo vrednosti parametrov:

- $a = 1.96 \times 10^{-1} \pm 5. \times 10^{-3}$
- $b = 9.7 \times 10^{-3} \pm 3. \times 10^{-4}$

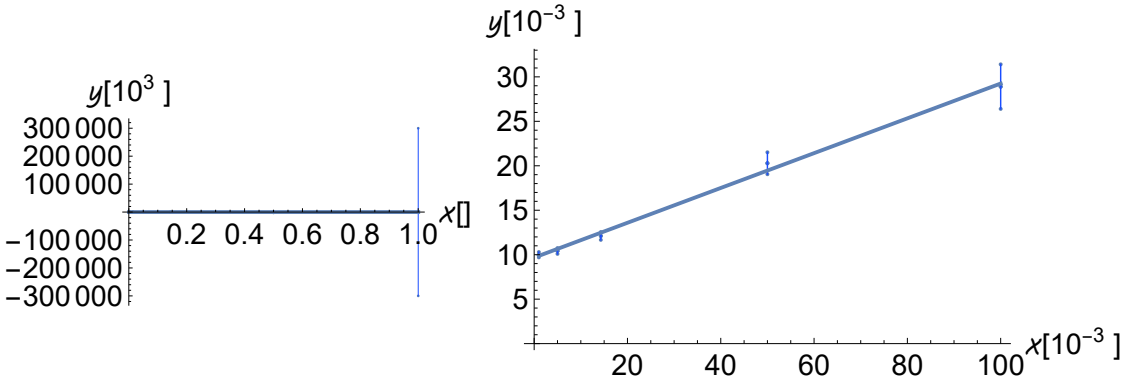

Farmakološke meritve in prilegan linearizirani model

Od tod $y_0 = \frac{1}{b} = 103.4 \pm 2.8$ in $a = \frac{a}{b} = 20.2 \pm 1.1$. Vidimo, da sta tako dobljena parametra drugačna od tistih, ki ju dobimo pri direktnem fitu, sta pa dokaj blizu.

RAZŠIRJENI MODEL

Poglejmo še splošnejši model $\boxed{y = \frac{y_0}{1+\left(\frac{a}{x}\right)^p}}$.

S prileganje grafa $\frac{y_0}{1+\left(\frac{a}{x}\right)^p}$ na meritve dobimo vrednosti parametrov:

- $y0 = 1. \times 10^2 \pm 2.$
- $a = 1.98 \times 10^1 \pm 1.$
- $p = 1.36 \pm 8. \times 10^{-2}$
- $\frac{\chi^2}{N-M} = 1.56$

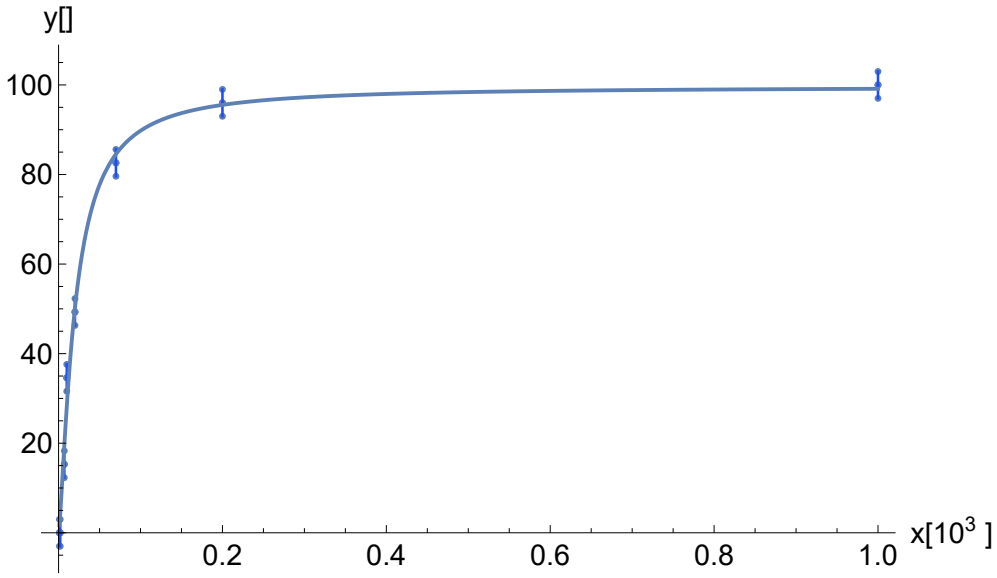

Farmakološke meritve in prilegan razširjeni model

STATISTIČNA OPRAVIČENOST

Če predpostavimo, da je negotovost 3 pravilna, je uvedba novega parametra statistično upravičena. To je, ker mora $\frac{\chi^2}{N}$ priti okoli 1, kar približno drži za razširjeni model, ne pa za osnovnega. Za pravilen model pričakujemo, da seka $\approx 68\%$ točk z napakami. Razširjeni model seka $\frac{5}{8}$ točk, osnovni pa $\frac{2}{8}$. Po Bernuliju lahko ocenimo, da je sekanje le 2 ali manj točk zelo neverjetno $\sim 1.6\%$.

2.) ČISTILNOST LEDVIC

Zanima nas, kako hitro ledvice izločajo neko radioaktivno snov. Opazujemo časovni poteg radioaktivne aktivnosti v ledvicah. Poskusimo ga opisati z različnimi modeli. Navodilo nič ne pravi o negotovostih, vemo pa, da ne morejo biti manjše od $\sqrt{N}$, tako, da jih vzemimo kar $\sqrt{N}$. Prilegamo naslednje modele:

EENORAZDELČNI MODEL

S prileganje grafa $a1\, e^{-t\,\lambda 1}$ na meritve dobimo vrednosti parametrov:

- $a1 = 1.05 \times 10^4 \pm 2. \times 10^2$
- $\lambda 1 = 1.04 \times 10^{-3} \pm 4. \times 10^{-5}$
- $\frac{\chi^2}{N-M} = 212.04$

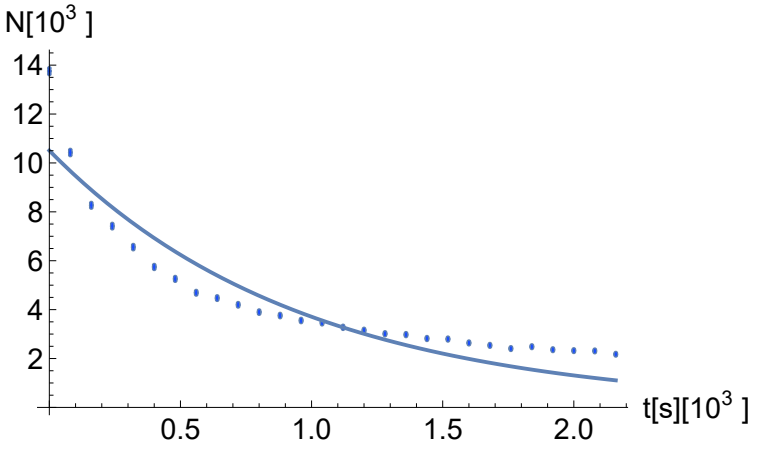

S prileganje grafa $c + a1\, e^{-t\,\lambda 1}$ na meritve dobimo vrednosti parametrov:

- $a1 = 1.03 \times 10^4 \pm 1. \times 10^2$
- $\lambda 1 = 2.92 \times 10^{-3} \pm 7. \times 10^{-5}$
- $c = 2.61 \times 10^3 \pm 4. \times 10^1$
- $\frac{\chi^2}{N-M} = 25.09$

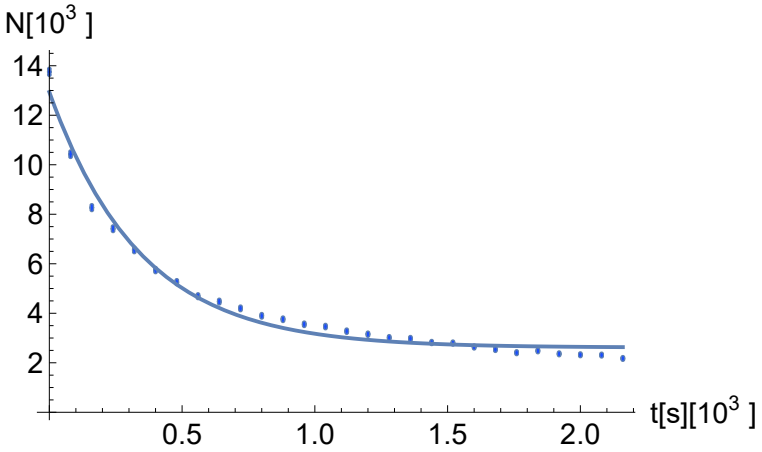

DVORAZDELČNI MODEL

S prileganje grafa $a1\, e^{-t\,\lambda 1} + a2\, e^{-t\,\lambda 2}$ na meritve dobimo vrednosti parametrov:

- $a1 = 8.03 \times 10^{3} \pm 9. \times 10^{1}$
- $\lambda 1 = 5.2 \times 10^{-3} \pm 1. \times 10^{-4}$
- $a2 = 5.55 \times 10^{3} \pm 9. \times 10^{1}$
- $\lambda 2 = 4.5 \times 10^{-4} \pm 1. \times 10^{-5}$
- $\frac{\chi^2}{N-M} = 3.19$

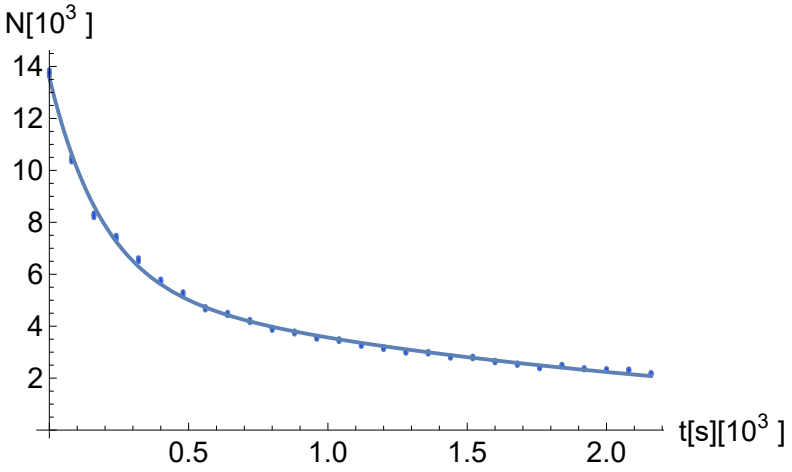

S prileganje grafa $c + a1\, e^{-t\,\lambda 1} + a2\, e^{-t\,\lambda 2}$ na meritve dobimo vrednosti parametrov:

- $a1 = 6.3 \times 10^{3} \pm 2. \times 10^{2}$
- $\lambda 1 = 1.44 \times 10^{-3} \pm 6. \times 10^{-5}$
- $a2 = 5.4 \times 10^{3} \pm 2. \times 10^{2}$
- $\lambda 2 = 8.1 \times 10^{-3} \pm 3. \times 10^{-4}$
- $c = 1.99 \times 10^{3} \pm 5. \times 10^{1}$
- $\frac{\chi^2}{N-M} = 1.67$

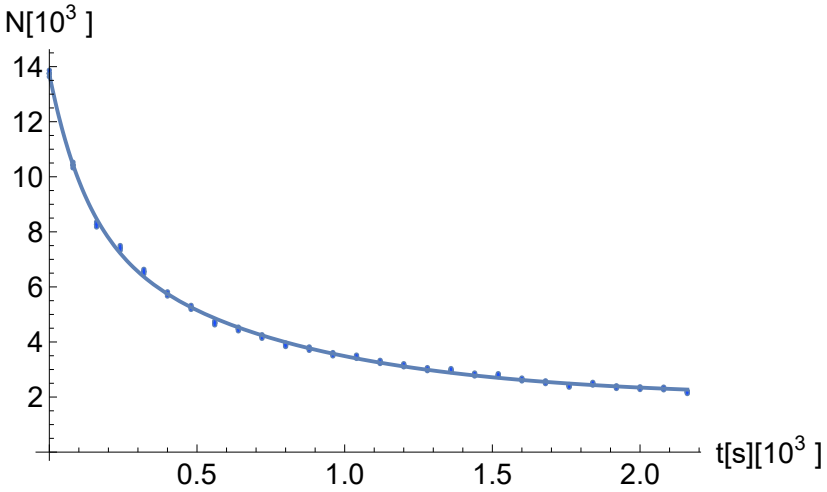

$\sqrt{t}$ MODEL

S prileganje grafa $a1\, e^{-\sqrt{t}\,\lambda 1}$ na meritve dobimo vrednosti parametrov:

- $a1 = 1.402 \times 10^{4} \pm 9. \times 10^{1}$
- $\lambda 1 = 4.27 \times 10^{-2} \pm 3. \times 10^{-4}$
- $\frac{\chi^2}{N-M} = 14.36$

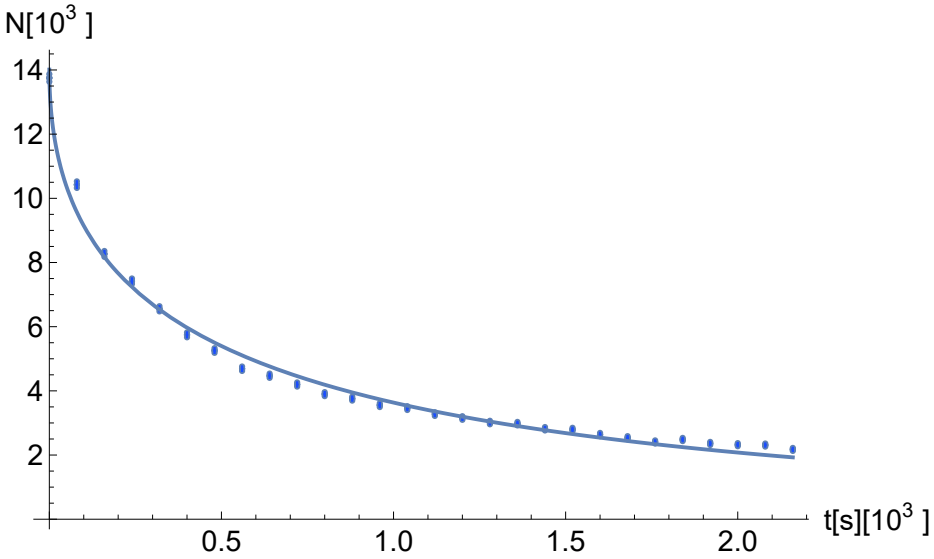

S prileganje grafa $c + a1\, e^{-\sqrt{t}\,\lambda 1}$ na meritve dobimo vrednosti parametrov:

- $a1 = 1.37 \times 10^{4} \pm 1. \times 10^{2}$
- $\lambda 1 = 4.7 \times 10^{-2} \pm 1. \times 10^{-3}$
- $c = 5. \times 10^{2} \pm 1. \times 10^{2}$
- $\frac{\chi^2}{N-M} = 9.64$

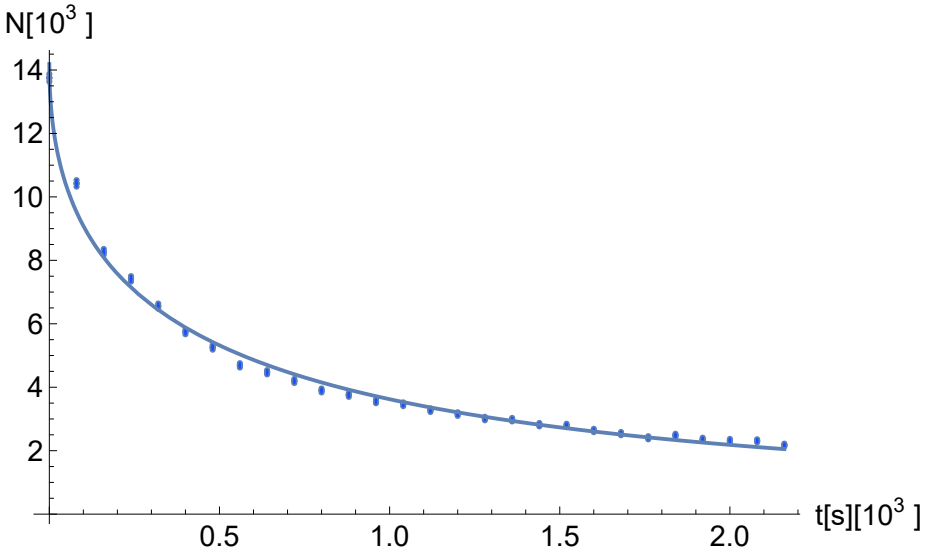

PRIMERJAVA

Vidimo, da je ujemanje pri dvorazdelčnem modelu veliko boljše.

UPRAVIČENOST KONSTANTE

Vidimo, da konstanten člen za sevanje ozadja vse modele bistveno izboljša. Najbolj bistven primer je dvorazdelčni model, kjer se $\frac{\chi^2}{N-M}$ zmanjša iz 3.19 na 1.67. Poleg tega za dober fit pričakujemo, da ne bo veliko zaporednih točk na isti strani krivulje, ampak bolj, kot bi metali kovanec. Že od očesa se vidi, da dodatek konstante skrajša sklope točk na isti strani krivulj.

3.) MAGNETNI SPEKTROMETER

Za uporabo visokoločljivostnega magnetnega spektrometra potrebujemo preslikavo, ki iz izmerjenih količin rekonstruira parametre trajektorije delcev, potrebne za izračun energije in drugih kinematičnih količin. θ_{tg} je disperzijski kot na tarči v stopinjah, x_{fp} položaj v goriščni ravnini v milimetrih in θ_{fp} kot v goriščni ravnini v stopinjah. Natančnosti meritev kotov so velikostnega reda miliradianov (vzemimo .001), položajev pa okrog milimetra. Iščemo varčni model $\theta_{tg}(\theta_{fp}, x_{fp})$. Najprej poglejmo točke, ki jim prilegamo funkcijo.

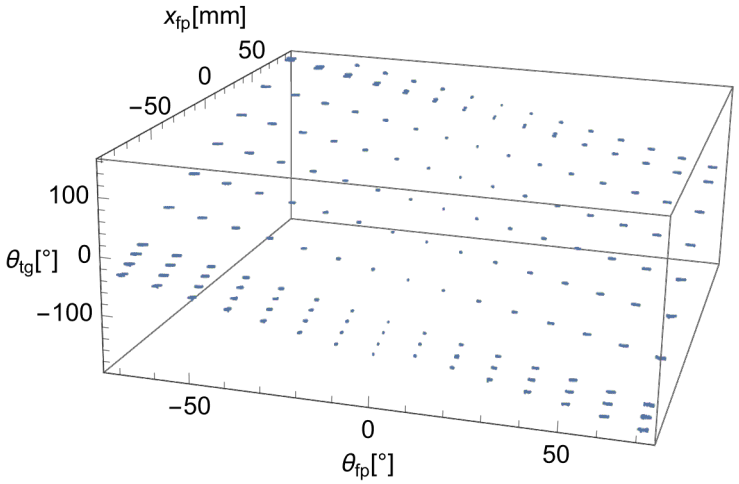

Meritve $(\theta_{fp}, x_{fp}, \theta_{tg})$

Načeloma bi lahko delal tudi z lokalnimi ocenami napak, ki bi jih izračunal za vsako gručo točk.

Vidimo, da tvorijo, lepo pohlevno ploskev. Ker nimamo kake fizikalne osnove, za izbiro modela, vzamemo kar polinome v θ_{fp} in x_{fp}: $\Sigma_{i,j}\, a_{i,j}\, \theta_{fp}{}^{i}\, x_{fp}{}^{j}$. Za iskanje koeficientov $a_{i,j}$ uporabimo *LinearModelFit*. Ta izvede SVD razcep za računanje psevdoinverza pravokotne matrike. Na naslednji strani so narisani prilegani grafi za 2×2, 4×4 in 21×21 parametrov.

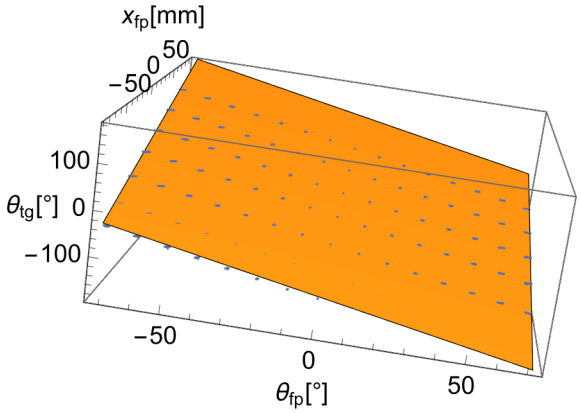

$i \leq 1,\ j \leq 1$

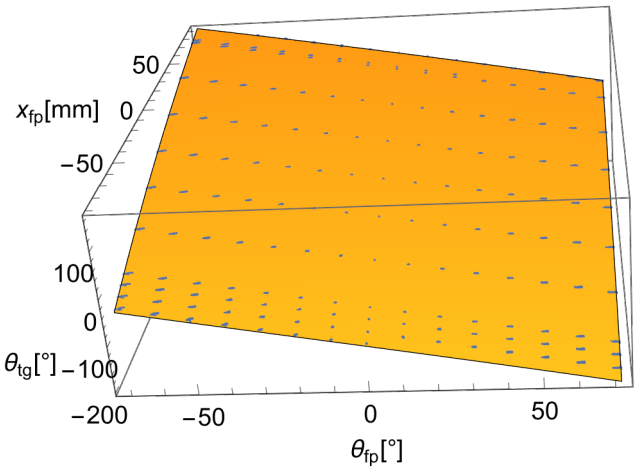

$i \leq 3,\ j \leq 3$

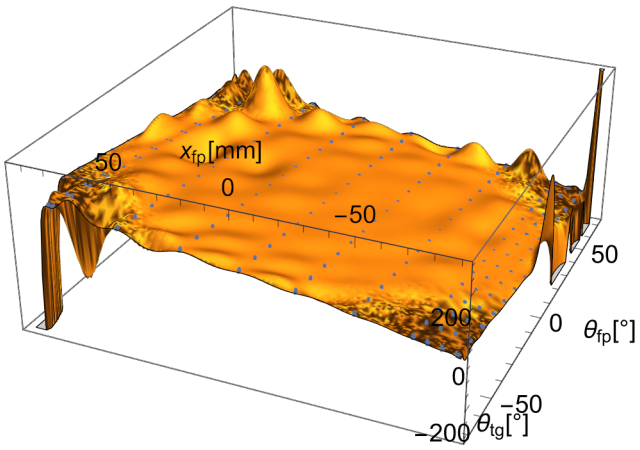

$i \leq 20,\ j \leq 20$

Od očesa se vidi, da ima prvi graf premalo parametrov, drugi primerno število parametrov, tretji pa mnogo preveč (overfiting). Poglejmo, kako $\frac{\chi^2}{N-M}$ pada z višanjem stopnje polinoma n.

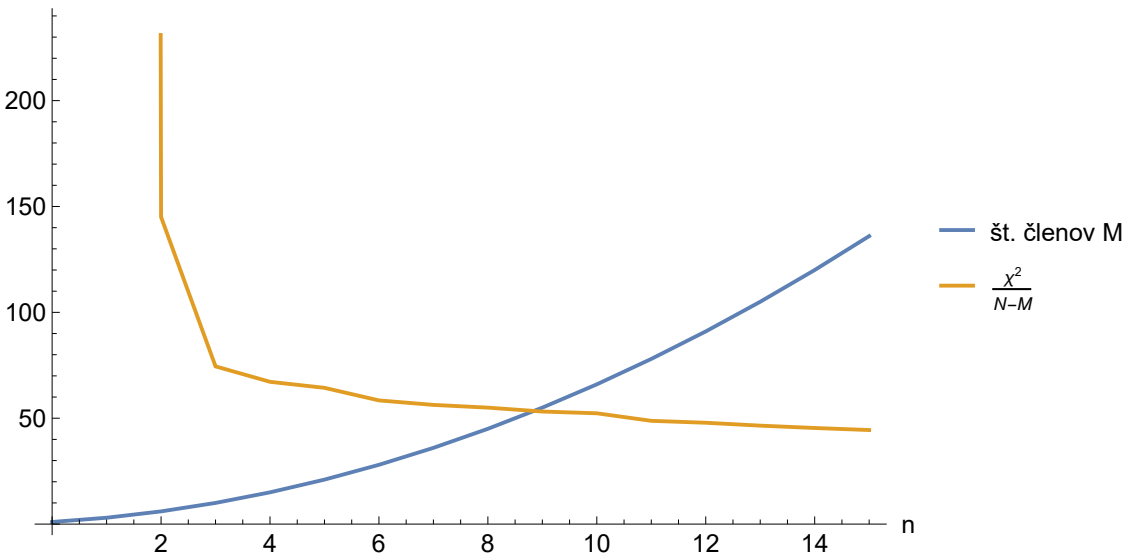

Padanje χ^2 z dodajanjem parametrov

Vidimo, da se nam za varčen model splača vzeti polinom 3. stopnje, ki ima $\frac{(3+1)(3+2)}{2}$ = 10 členov/ parametrov. Vidimo tudi, da smo napake θ_{tg} močno podcenili in so v resnici bolj .007. Prilegan polinom 3. stopnje je:

$$1.99924 + 1.14355\, x_{fp} - 0.00220003\, x_{fp}^2 + 3.21472 \times 10^{-6}\, x_{fp}^3 - 1.17177\, \theta_{fp} + 0.0000198643\, x_{fp}\, \theta_{fp} + 2.43659 \times 10^{-8}\, x_{fp}^2\, \theta_{fp} - 0.000441792\, \theta_{fp}^2 - 2.15078 \times 10^{-6}\, x_{fp}\, \theta_{fp}^2 - 1.82983 \times 10^{-6}\, \theta_{fp}^3$$

Vidimo, da 3 od teh členov nastopajo v zelo majhni količini, zato lahko brez večje škode vzamemo še varčnejši model s 7 parametri

$$1.99924 + 1.14355\, x_{fp} + 3.21472 \times 10^{-6}\, x_{fp}^3 - 1.17177\, \theta_{fp} + 0.43659 \times 10^{-8}\, x_{fp}^2\, \theta_{fp} - 2.15078 \times 10^{-6}\, x_{fp}\, \theta_{fp}^2 - 1.82983 \times 10^{-6}\, \theta_{fp}^3$$

4.) 3D ORIENTACIJA IN LEGA 2D OBLIKE

Iz slike 2D oblike želimo ugotoviti kje v prostoru se nahaja in kako je obrnjena. Obliko izrežemo iz papirja in skeniramo, potem pa jo slikamo v neznani legi in orientaciji v prostoru:

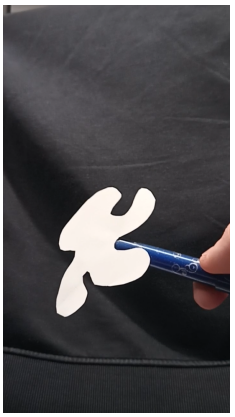

Skenirano obliko po svetlosti ločimo od ozadja. Nato poiščemo robne piksle. To so piksli iz oblike, ki jih ne obkroža 8 pikslov iz oblike. Z bucket fill algoritmom posortiramo rob, da dobimo vrstni red pislov (spreod po robu). to ustrezno vzorčimo in dobimo večkotnik. Tega še ustrezno reskaliramo in centriramo. Dobimo:

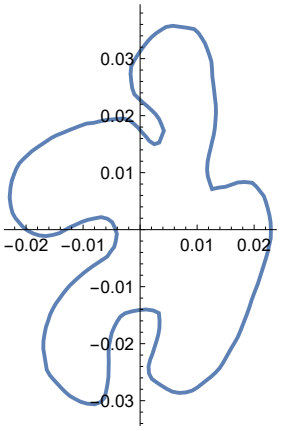

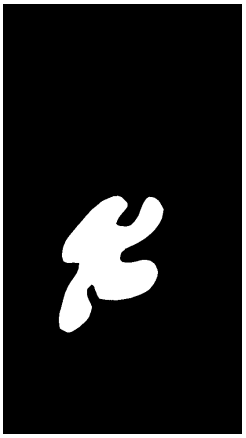

Ta večkotnik zdaj lahko poljubno premikamo in vrtimo, na koncu pa ga projeciramo skozi kamero na ravnino $\perp$ na snemalno os kamere. Tako za poljubno lego in orientacijo oblike lahko izračunamo, kaj bi morala videti kamera. Naš model ima 6 parametrov: 3 koordinate težišča in 3 kote. Parametre lahko ročno nastavimo napribližno začetno vrednost (kot je prikazano na posnetku). :

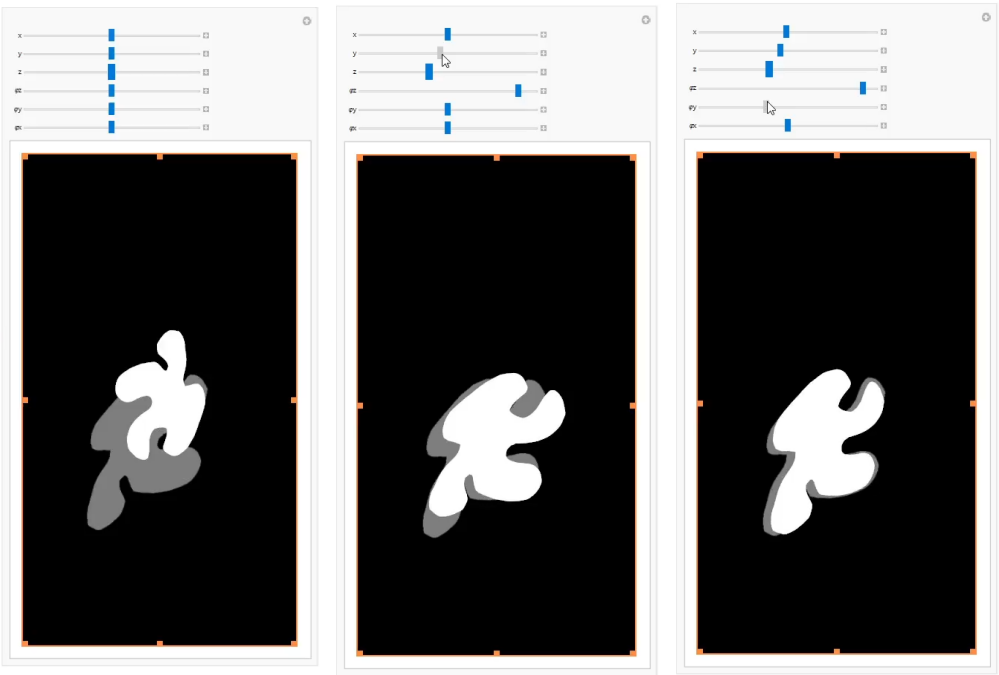

Od tu naprej poženemo minimizacijo χ^2. V tem primeru sta modelska in izmerjena funkcija le karateristični funkciji (0, 1). χ^2 je tako kvadrat števila pikslov, kjer se model in meritev ne prekrivata. Na naslednji strani je priložena koda:

In[∘]:=

```
Oglji[večkotnik_,rt_,{φz_,φy_,φx_}]:=(
    rt+RollPitchYawMatrix[{φz,φy,φx}].{#1,#2,0}
)&@@@večkotnik;
Projekcija[r_]:=r/r[[3]][[;;2]];

χna2[meritev_,večkotnik_,{x_,y_,z_},{φz_,φy_,φx_},αkx_]:=
Module[{SlOzDim,OgljiPr,plr,napoved},
    SlOzDim=Reverse@Dimensions@meritev;
    OgljiPr=Projekcija/@Oglji[večkotnik,{x,y,z},{φz,φy,φx}];
    plr=1.{Tan[αkx/2]{-1,1},SlOzDim[[2]]/SlOzDim[[1]] Tan[αkx/2]{-1,1}};
    napoved=ImageData[ImageResize[Show[
        Graphics@{
            GrayLevel@1,
            Polygon@OgljiPr
        },
        PlotRange→plr,
        ImageSize→SlOzDim,
        Background→GrayLevel@0
    ],SlOzDim]];
    napoved=Total[napoved,{3}]/3;
    Total@Total[(meritev-napoved)^2]
];


meritev=ImageData@[redacted];

večkotnik0=Import@FileNameJoin@{NotebookDirectory[],"večkotnik0.mx"};
večkotnik=večkotnik0[[;;;;50]];
RtežVečkotnik=Mean@večkotnik;
večkotnik=(#-Round@RtežVečkotnik)&/@večkotnik;
večkotnik/=34567.;

χna2[meritev,večkotnik,{-.002,-.016,.078},{2.75,-.27,.1},70°]
```

Out[∘]=

11 189.4

Tako bi se dalo tudi slediti premikanju oblike v videu, a bi to računalo zelo dolgo časa. Verjetno bi bilo treba le enkrat ročno poiskati približne vrednosti, saj bi na vsaki naslednji sliki začeli z legami in orientacijami iz prejšnje slike.

Zanimiva posplošitev bi bila orientacija in lega poljubne 3 *D* oblike na posnetku. Za to bi mogli imeti 3 *D* scan oblike.

ZAKLJUČEK

Naučili smo se, da linearizacija spremeni izluščene parametre, spoznali razdelčni eksponentni model in pogledali še primer prileganja 2 D funkcije veliko parametri.