MODELSKA ANALIZA 1

11: OPTIMALNO FILTRIRANJE

GAL ZAJC: 28242041

FMF, 2024/2025

UVOD

Kadar z zaporednimi meritvami spremljamo časovni razvoj procesa, katerega dinamiko poznamo, lahko s filitriranjem dosežemo občutno boljšo natančnost, kot jo dajejo surove meritve. Kalmanov filter deluje na principu optimalnega uteževanja linearne napovedi stanja ter novih meritev, kar doseže s sprotnim vodenjem evidence o kovarianci trenutne ocene stanja.

Naj bo x_n vektor stanja sistema ob času t_n, $\boldsymbol{P_n}$ pa pripadajoča kovariančna matrika, ki opisuje njegovo statistično negotovost. Potrebujemo še začetno stanje $\boldsymbol{x_0}^+$ ter kovarianco $\boldsymbol{P_0}^+$

ki ju običajno dobimo iz prve surove meritve. Komponentam stanja, ki niso na voljo, nastavimo velike začetne kovariance. Kalmanov filter poteka v dveh korakih. Prvi korak je izvedba časovnega koraka na trenutni napovedi stanja. Fizikalni sistem naj uboga časovno evolucijo $\boldsymbol{x_{n+1}} = \boldsymbol{F_n}.\boldsymbol{x_n} + \boldsymbol{c_n} + \boldsymbol{w_n}$, kjer je $\boldsymbol{F_n}$ prehodna matrika sistema, cn kontrolni vektor, wn pa vektor Gaussovega šuma s povprečjem 0 in kovariančno matriko $\boldsymbol{Q_n}$. Napovemo novo stanje $\boldsymbol{x_{n+1}}^-$ ter njegovo kovariančno matriko $\boldsymbol{P_{n+1}}^-$:

- $$\boxed{\begin{aligned} \boldsymbol{x_{n+1}}^- &= \boldsymbol{F_n}.\boldsymbol{x_n} + \boldsymbol{c_n} \\ \boldsymbol{P_{n+1}}^- &= \boldsymbol{F_n}.\boldsymbol{P_n}^+.\boldsymbol{F_n}^T + \boldsymbol{Q_n} \end{aligned}}$$

Sledi izboljšava te napovedi z novimi meritvami. V splošnem ne merimo neposredno komponent vektorja stanja $\boldsymbol{x_n}$, temveč neko linearno kombinacijo $\boldsymbol{z_n} = \boldsymbol{H_n}.\ \boldsymbol{x_n} + \boldsymbol{r_n}$, kjer je Hn matrika, ki določa, kaj merimo, $\boldsymbol{r_n}$ pa šum meritve s kovariančno matriko $\boldsymbol{R_n}$. Matrika $\boldsymbol{H_n}$ je lahko singularna, če merimo manj spremenljivk, kot je dimenzija sistema.

- $$\boxed{\begin{aligned} \boldsymbol{K_{n+1}} &= \boldsymbol{P_{n+1}}^-.\boldsymbol{H_{n+1}}^T.(\boldsymbol{R_{n+1}} + \boldsymbol{H_{n+1}}.\boldsymbol{P_{n+1}}^-\ \boldsymbol{H_{n+1}}^T)^{-1} \\ \boldsymbol{x_{n+1}}^+ &= \boldsymbol{x_{n+1}}^- + \boldsymbol{K_{n+1}}.(\boldsymbol{z_{n+1}} - \boldsymbol{H_{n+1}}.\boldsymbol{x_{n+1}}^-) \\ \boldsymbol{P_{n+1}}^+ &= (\boldsymbol{I} - \boldsymbol{K_{n+1}}.\boldsymbol{H_{n+1}}).\boldsymbol{P_{n+1}}^- \end{aligned}}$$

Prva enačba določa izboljšanje natančnosti stanja zaradi novih meritev, $\boldsymbol{K_{n+1}}$ je pa faktor ojačanja, ki določa, s kolikšno utežjo nova meritev prispeva k popravku.

1.)

Filtriramo trajektorijo avtomobila. Stanje je $\boldsymbol{x} = \begin{pmatrix} x \\ y \\ v_x \\ v_y \end{pmatrix}$. Nadzorni vektor je $\boldsymbol{c} = \begin{pmatrix} 0 \\ 0 \\ a_x \\ a_y \end{pmatrix} \Delta t$, prehodna matrika pa

$\boxed{\boldsymbol{F} = \begin{pmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}}$. Iz napake pospeška izhaja še $Q_n = \sigma_a{}^2\, \Delta t^2\, \mathrm{diag}(0, 0, 1, 1)$, šum meritev pa iz napak GPS podatkov ter hitrosti, $\boxed{R_n = \mathrm{diag}(\sigma_{xy}{}^2, \sigma_{xy}{}^2, \sigma_v{}^2, \sigma_v{}^2).}$ Podatki so vzorčeni vsakih $\Delta t = 1.783\, s$. Za pospeške in GPS podatke sta znani absolutni napaki $\sigma_{xy} = 25\, m$, $\sigma_a = 0.05\, \frac{m}{s^2}$, za hitrost pa poznamo relativno napako: $\sigma_v = 0.01\, ||\, v\, ||$, pri čmer napako vseeno navzdol omejimo na $1\, \mathrm{km}/h$.

Tako s kalmanovim filtrom iz danih podatkov napovemo trajektorijo vožnje

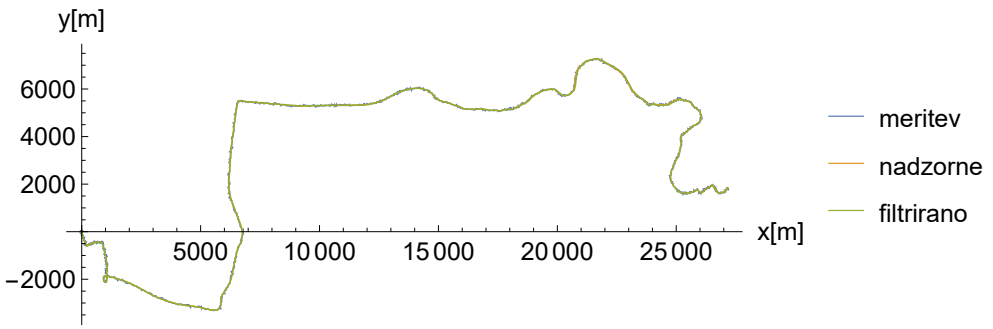

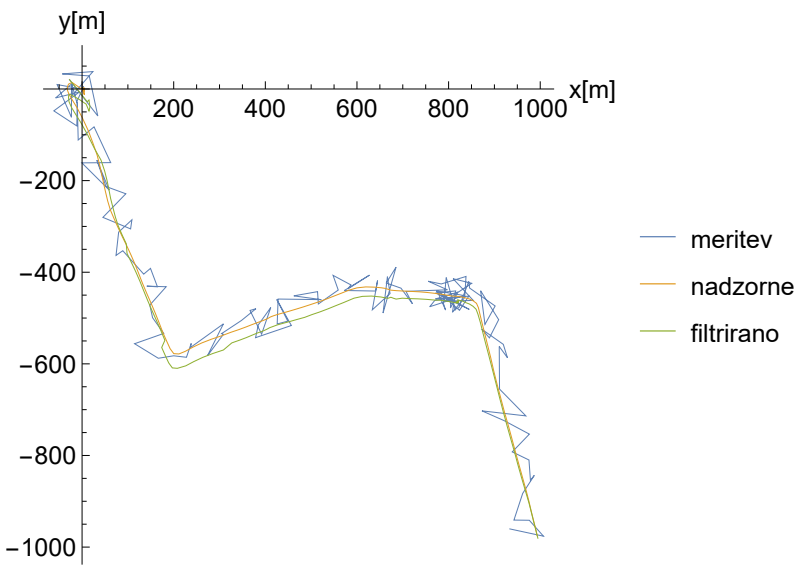

izmerjene, točne in kalmanovo filtrirane lege, ter povečava za prvih 140 točk

Glejmo povečani graf, ker se bolje vidi. Vidimo, da so meritve lege raztresene okoli točnih vrednosti. Kalmanov filter se prvi del poti zelo dobro ujema s točnimi vrednostmi, prvi ovinek pa ga odmakne od pravih vrednosti. Filter ne uspe uloviti novih meritev, se pa v naslednjem ovinku odmik filtra skoraj izniči in filter spet dobro dohaja meritve.

Podobno prikažemo za hitrost:

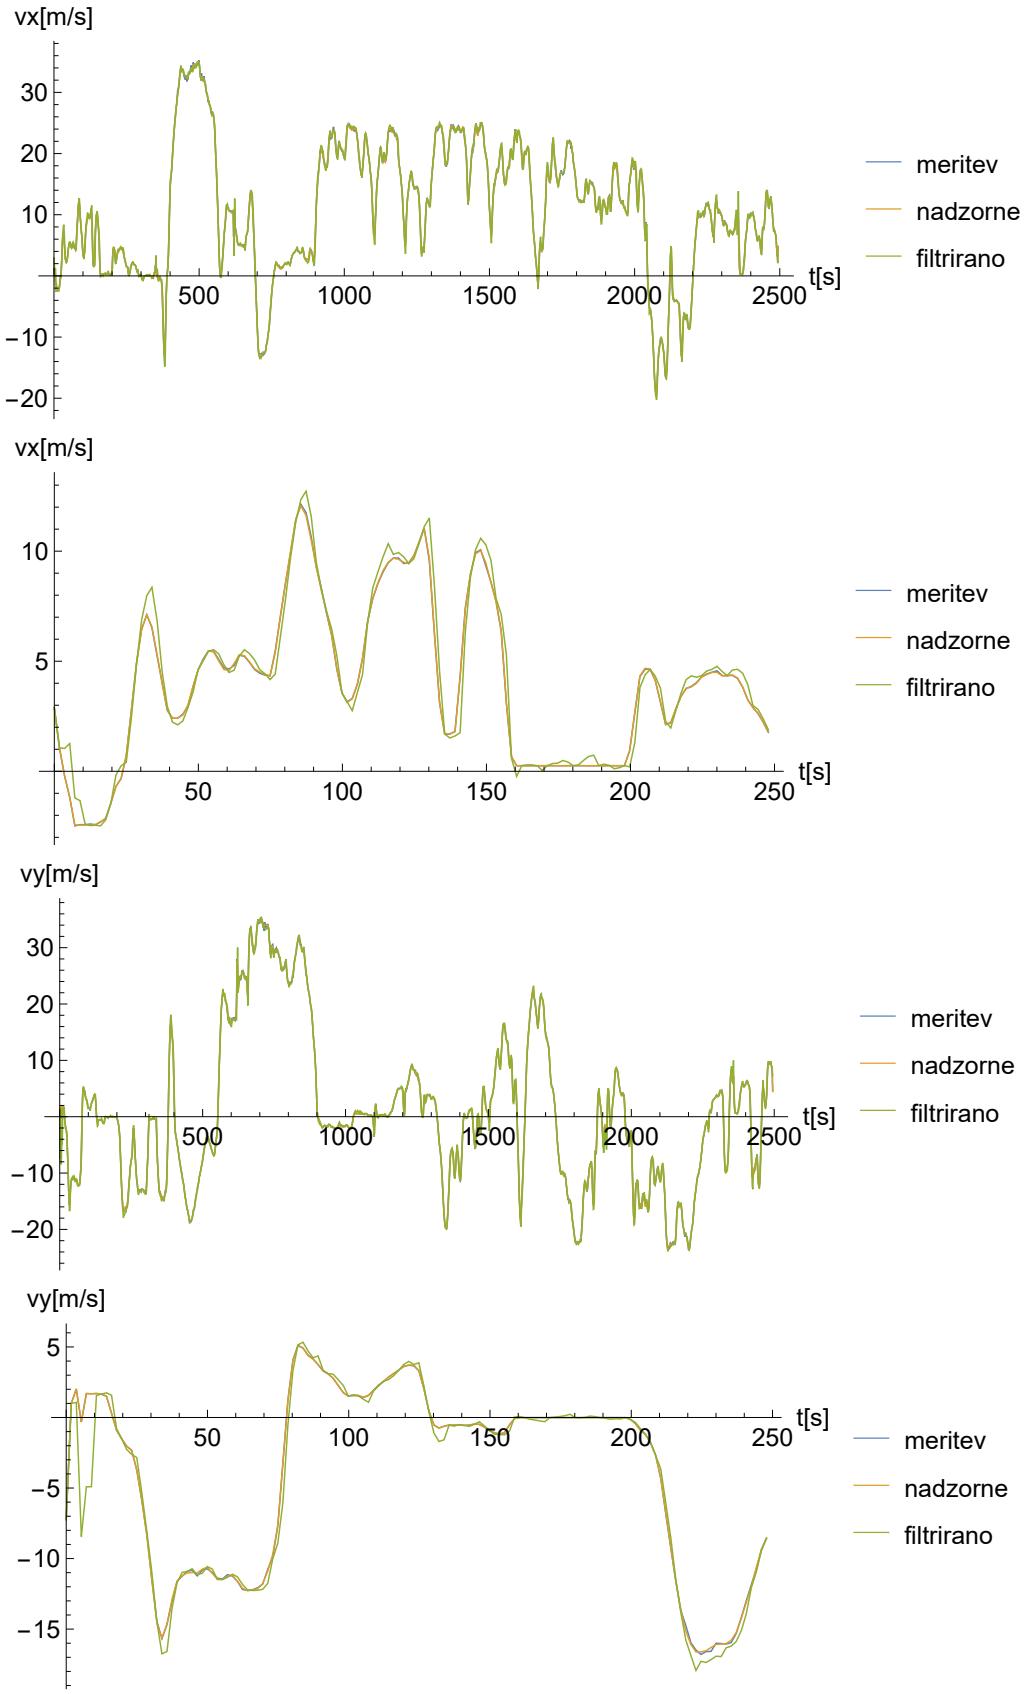

izmerjene, točne in kalmanovo filtrirane hitrosti

Vidimo, da so hitrosti že zelo natančno izmerjene, kalmanov filter ne pomaga.

Poglejmo še kako so izmerjene in filtrirane vrednosti porazdeljene okoli točnih:

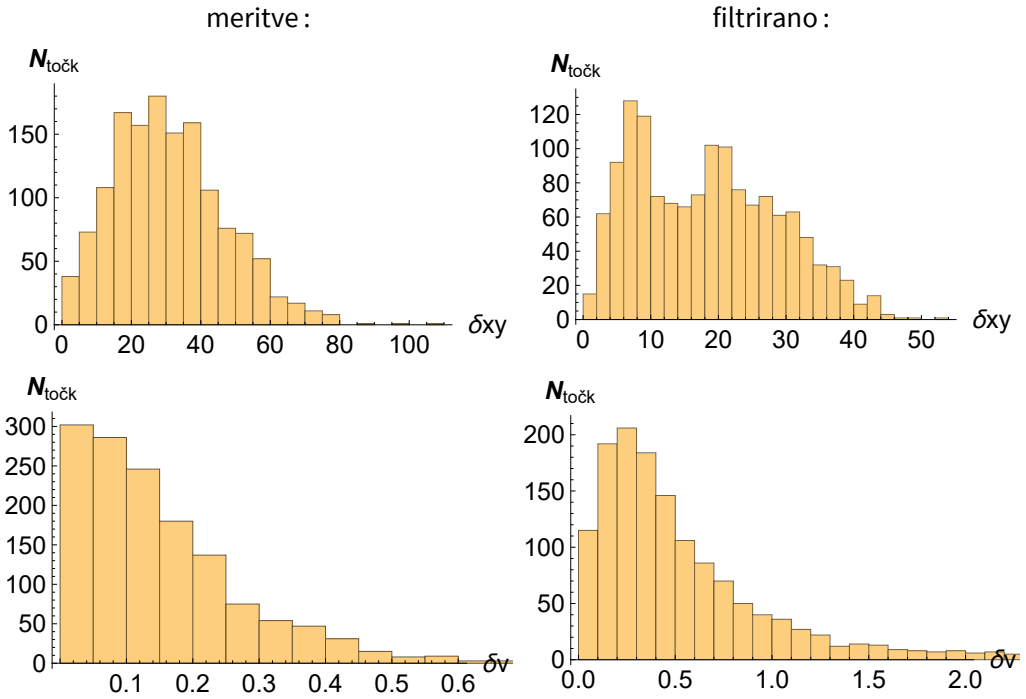

Porazdelitve okoli točnih vrednosti

Vidimo, da kalmanov filter kake 2-krat zmanjša odstopanja lege, odstopanja hitrosti pa poslabša.

Zdaj pa spreminjajmo vzorčenje lege. Na absvisah sledečih grafov je vsake katero meritev lege vzamemo na ordinatah pa poprečno odstopanje.

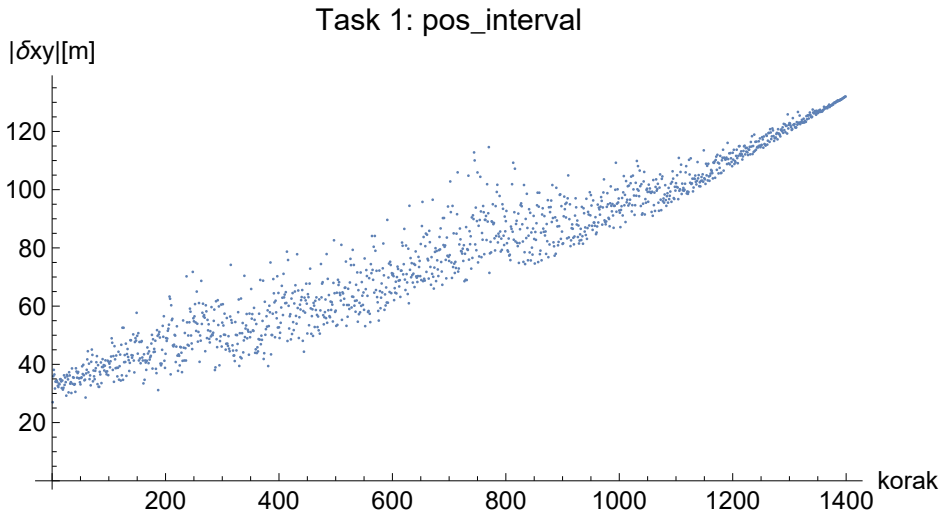

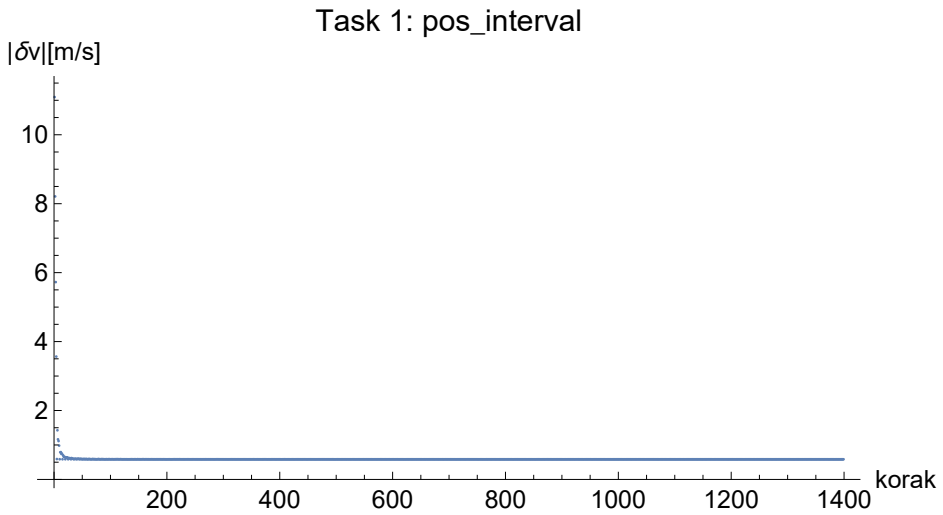

Vpliv vzorčenja lege na odstopanja

Vidimo, da je splošen trend: redkeje, kot vzorčimo, večje je odstopanje lege, pri hitrosti pa obratno. Vidimo, da je graf za odstopanja leg zelo zašumljen, a se na velikem območju trend vseeno dobro vidi.

Isto pogledamo še za vzorčenje hitrosti:

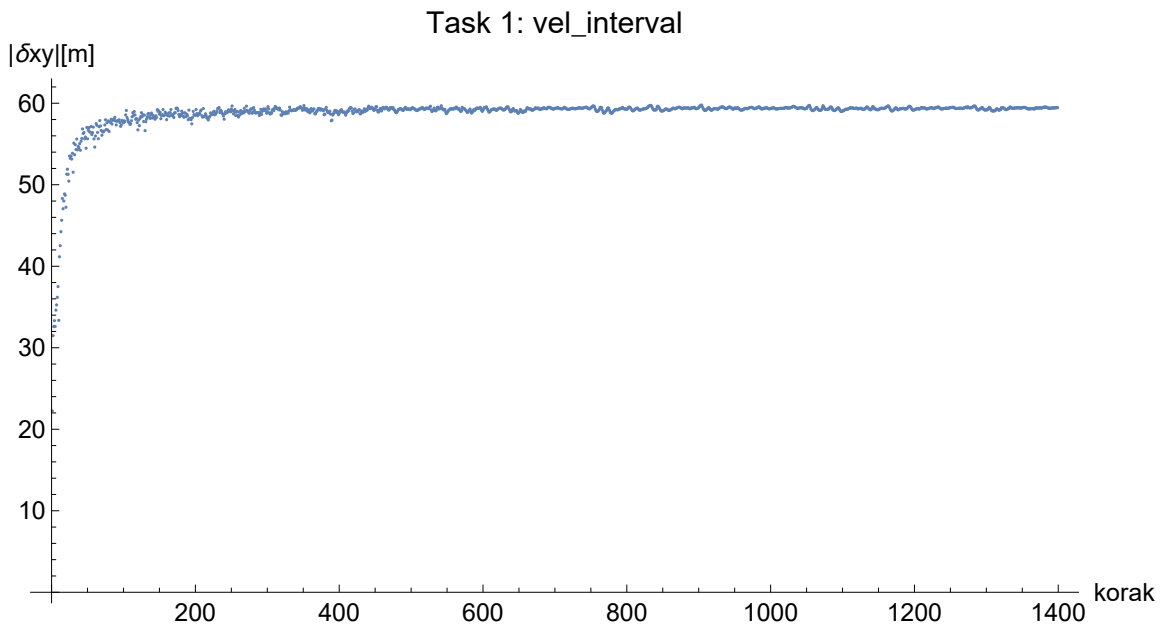

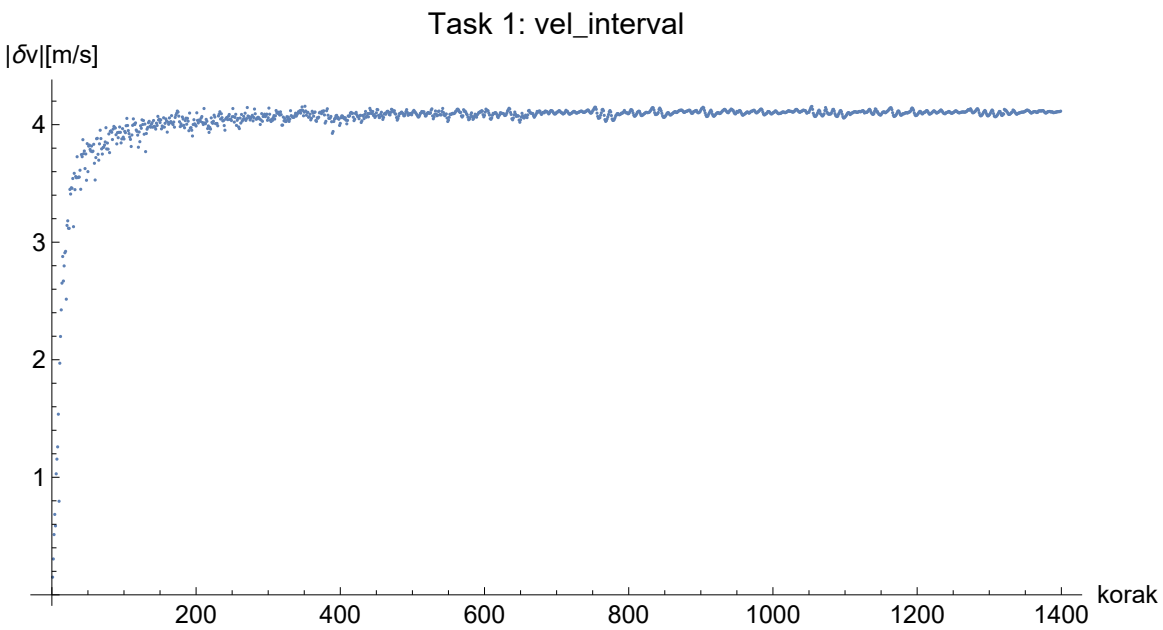

Vpliv vzorčenja hitrosti na odstopanja

Tukaj vidimo podoben trend za odstopanja le in hitrosti

Poglejmo še odvisnost povprečnega odstopanja od začetnih ocenjenih varianc.

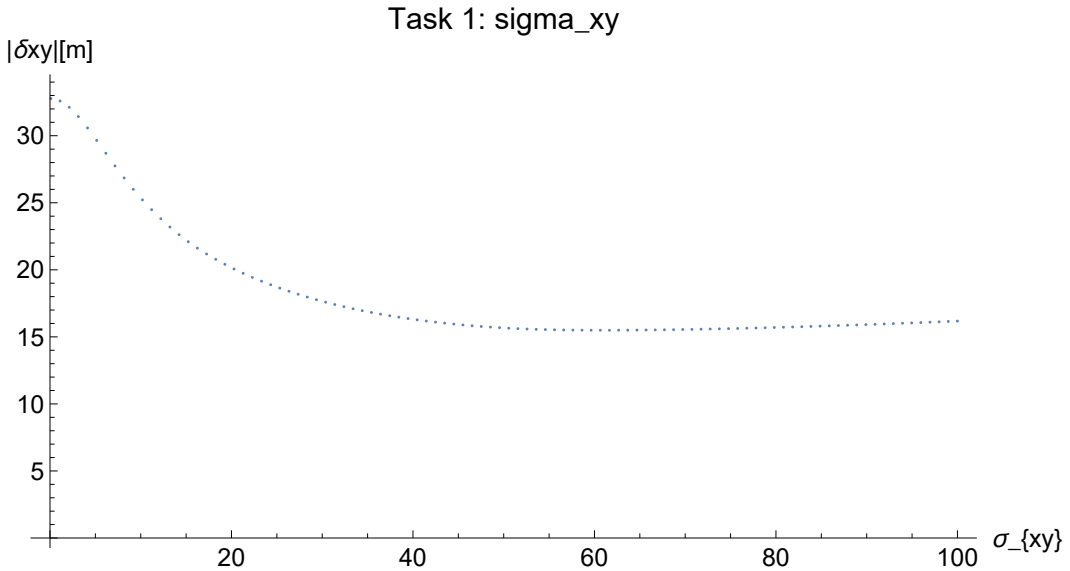

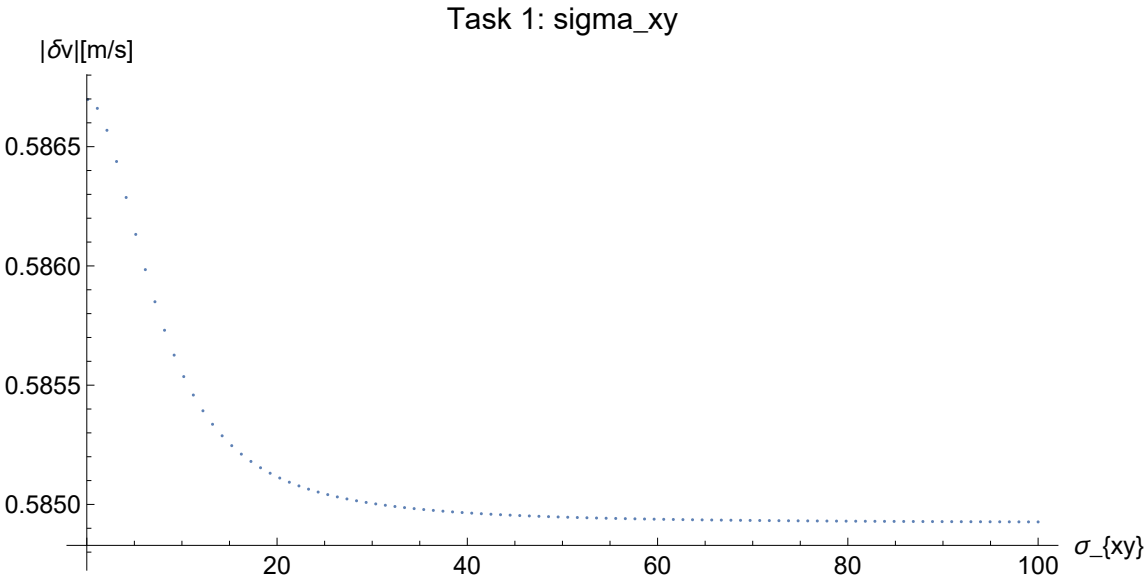

Vpliv ocene σ_{xy} na odstopanja

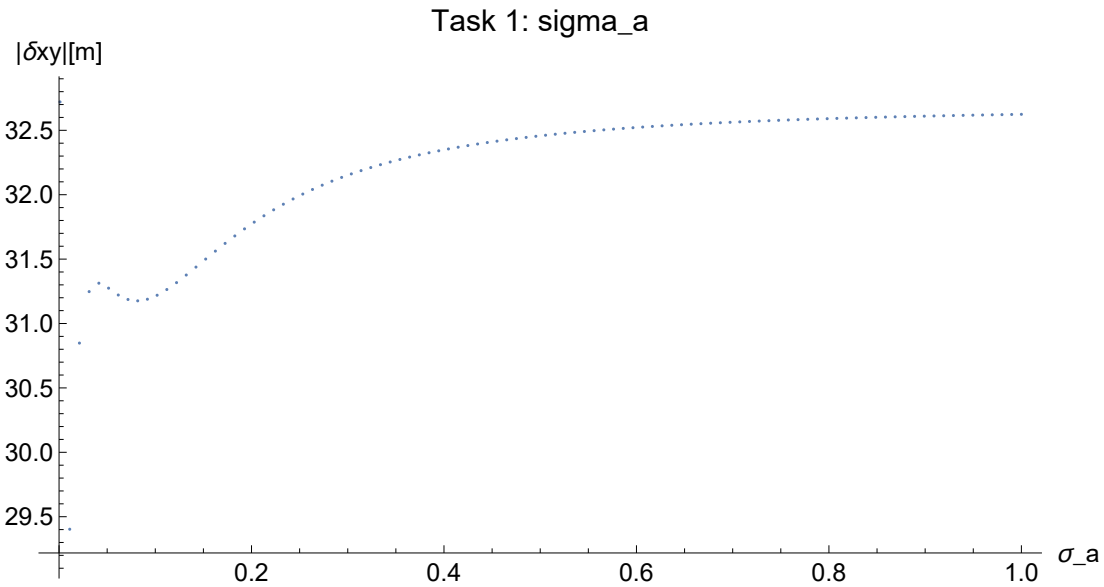

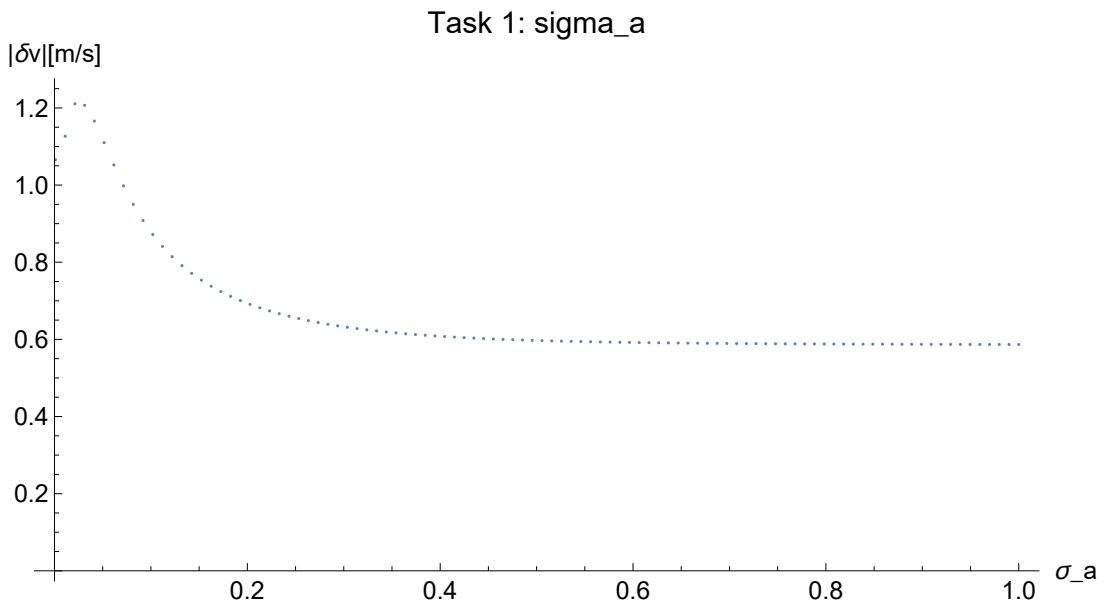

Vpliv ocene σ_a na odstopanja

Vidimo, da so te trendi izraziti (nezašumljeni). Z večanjem σ_{xy} se odstopanja zmanjšujejo, z večanjem σ_v se odstopanja leg večajo, odstopanja hitrosti pa padajo.

2.)

S telefonom lahko merimo le lokacijo in pospeške, informacij o hitrostih pa nimamo. Poglejmo, kako dobro lahko določimo trajektorijo vožnje in potek hitrosti, če podatki o hitrosti niso na voljo.

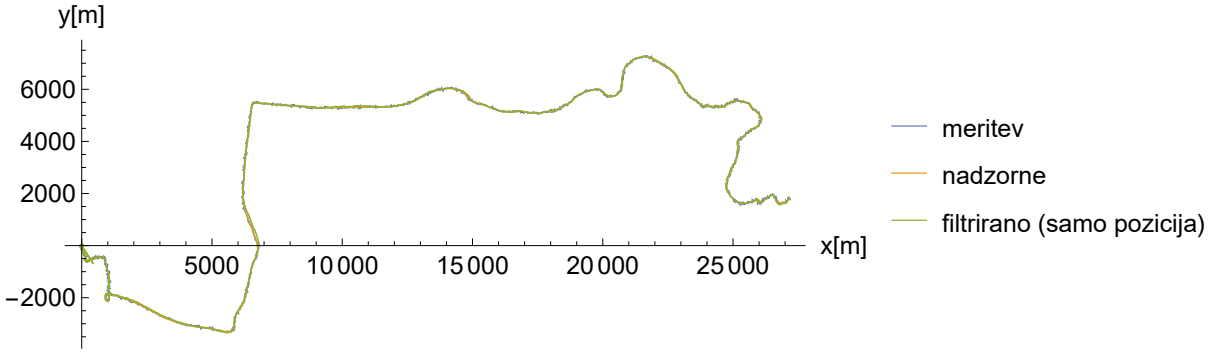

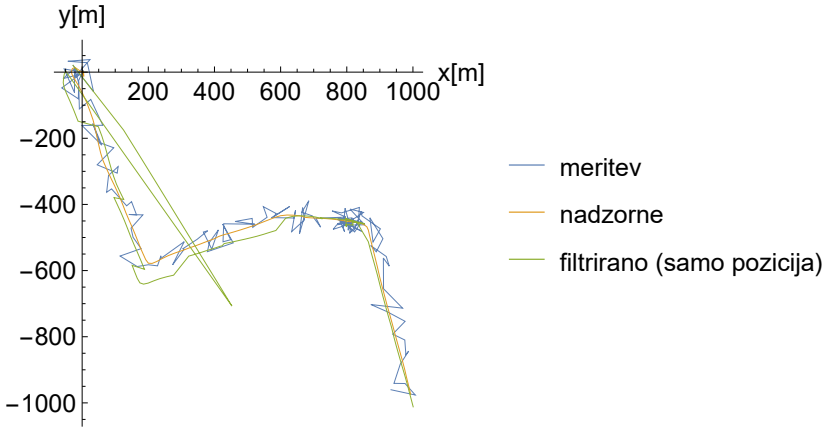

Vidimo, da je filtrirana trajektorija v temu primeru ostro razlomljena, “poskakuje”

Kaj pa obratno, če so znane samo hitrosti in pospeški?

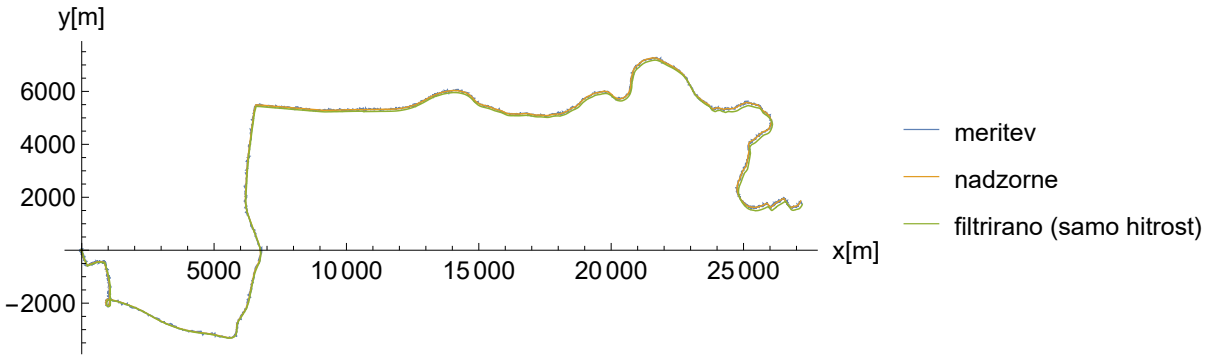

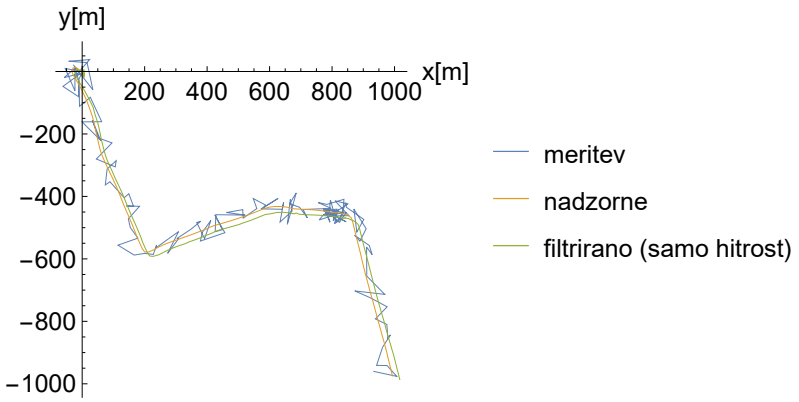

Dobimo precej gladko trajektorijo, ki pa precej odstopa od točnih meritev.

Poglejmo še kvantitativno odvisnosti odstopanj, kot v poglavju 1.

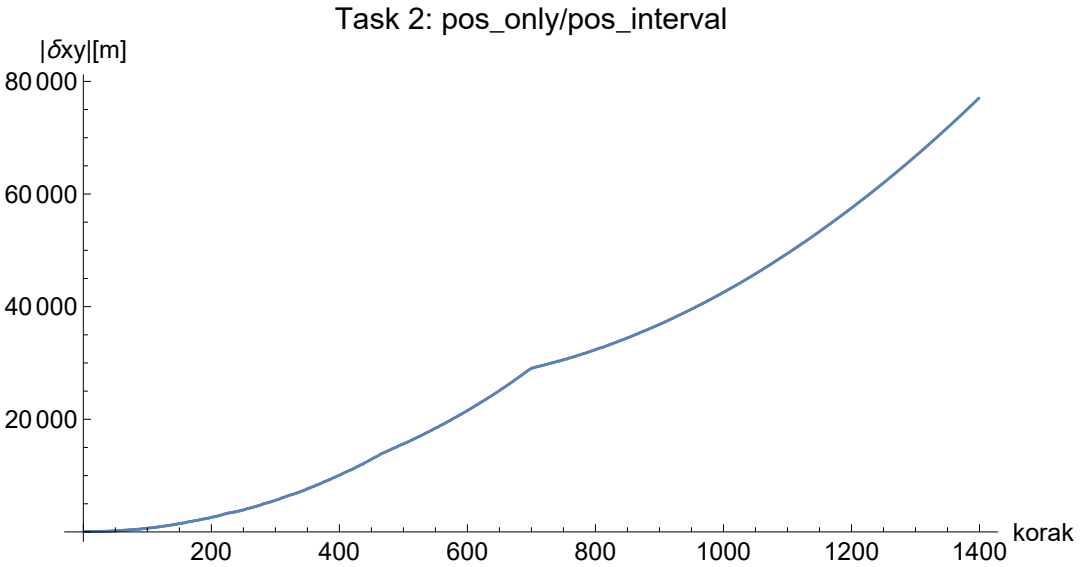

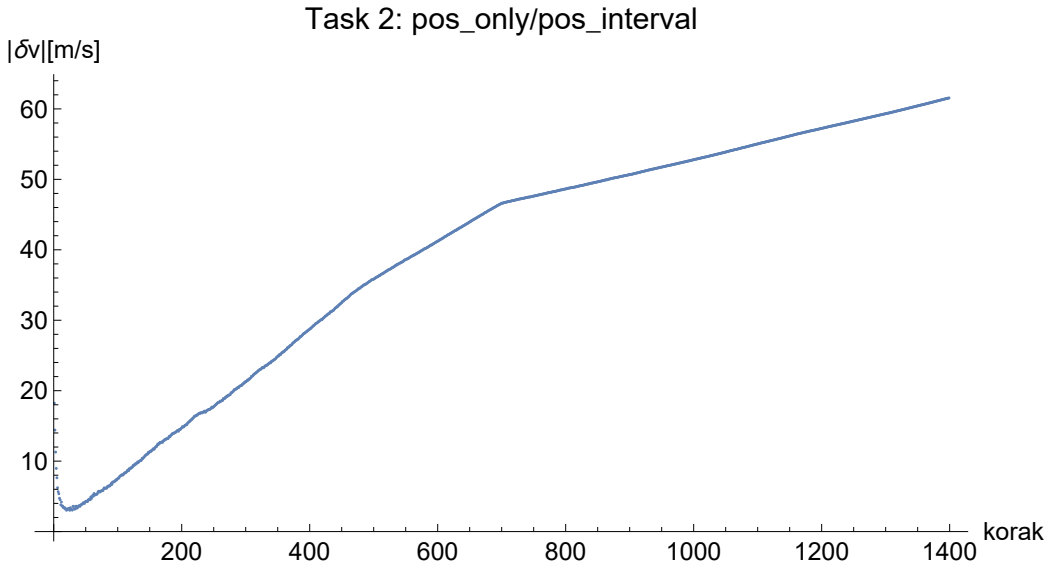

Vpliv vzorčenja lege na odstopanja. Znani sta samo lega in pospešek.

Vidimo, da to ni stabilno na redko vzorčeje leg. vseskupaj podivja. Dobimo trajektorije, ki so tudi po več deset km oddaljene od ceste, po kateri je peljal avtomobil in več deset $\frac{m}{s}$. Grafa sta najbolj prelomljena pri abscisi, od koder imamo le še 2 meritvi lege, ne več 3. Alternativno bi lahko na absciso dali, število izmerkov, ki jih vzamemo. Bi pa tak graf imel podobne probleme pri gostih vzorčenjih. Zanimivo se zdi, da pri gostih vzorčenjih odstopanje raste z večanjem gostosti vzorčenja (od desne proti levi, levo spodaj na grafu).

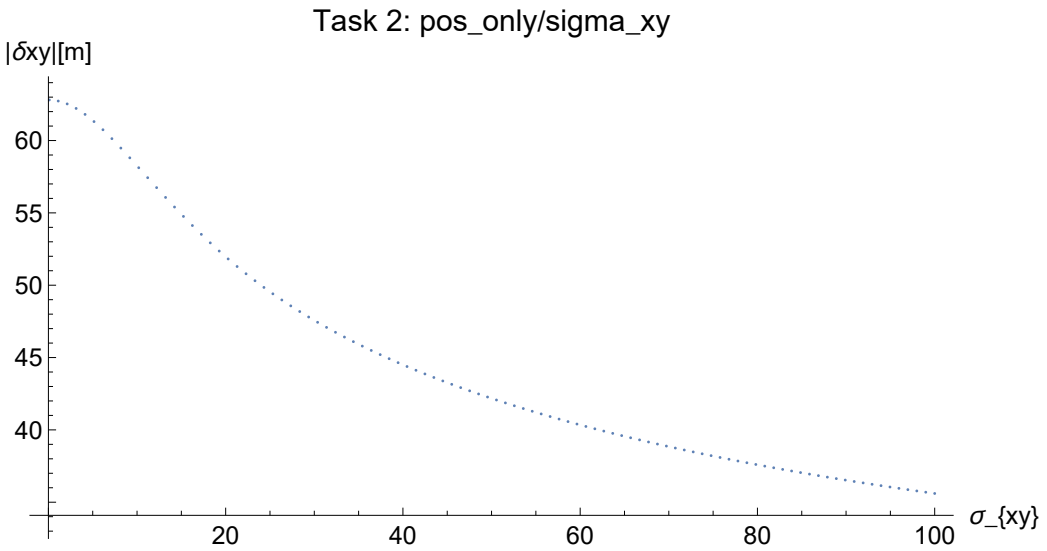

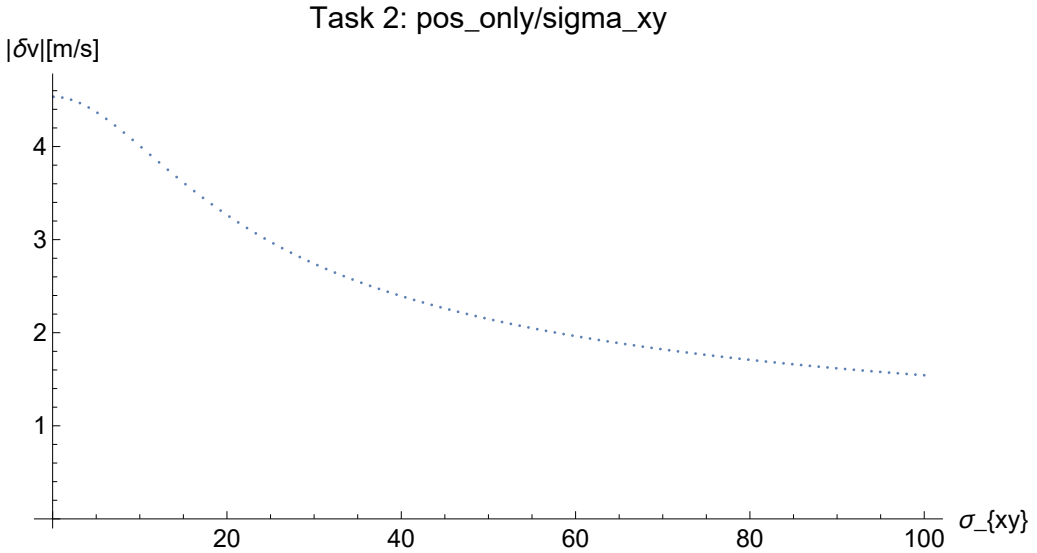

Vpliv ocene σ_{xy} na odstopanja, če so znane samo lege in pospeški

Malo večja odstopanja, sicer podobna odvisnost, kot v 1. poglavju.

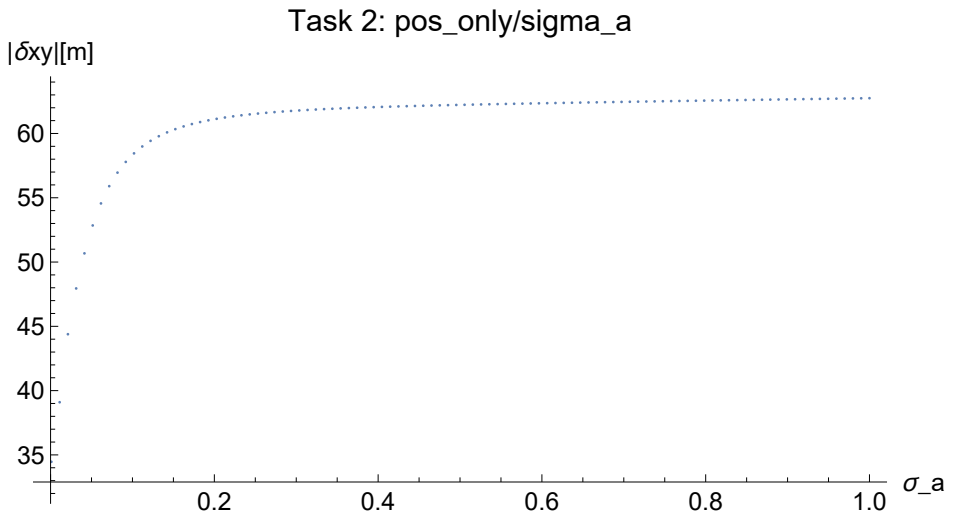

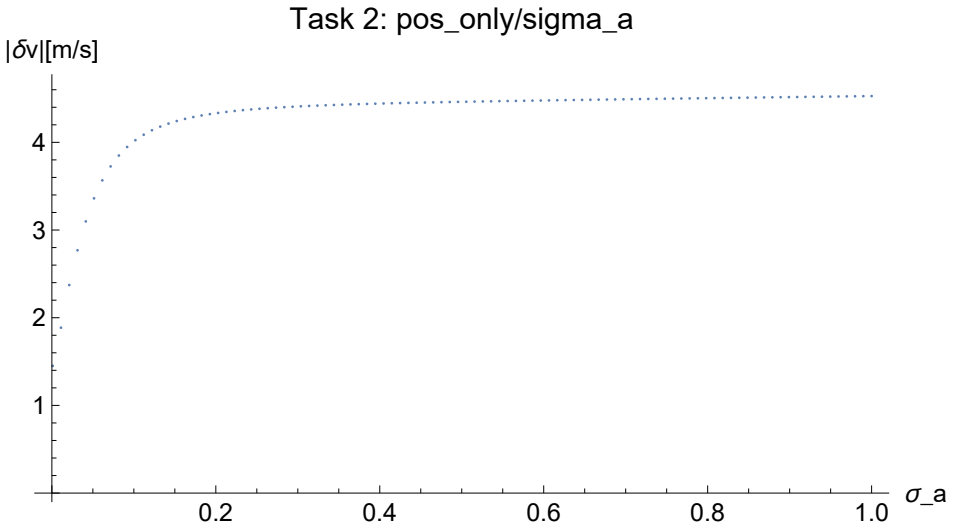

Vpliv ocene σ_a na odstopanja, če so znane samo lege in pospeški

Tokrat obe odstopanji naraščata z začetno oceno σ_a

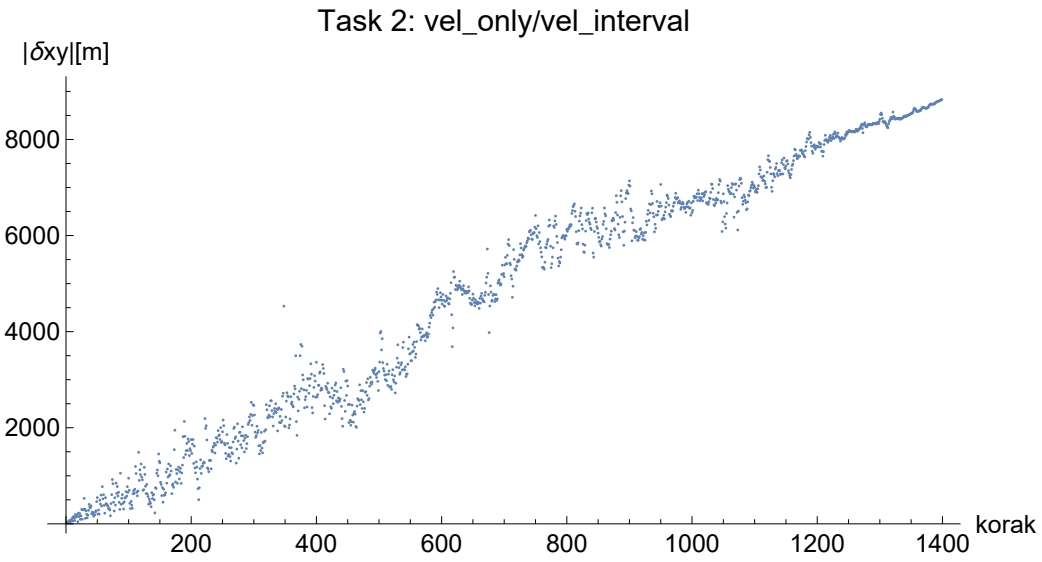

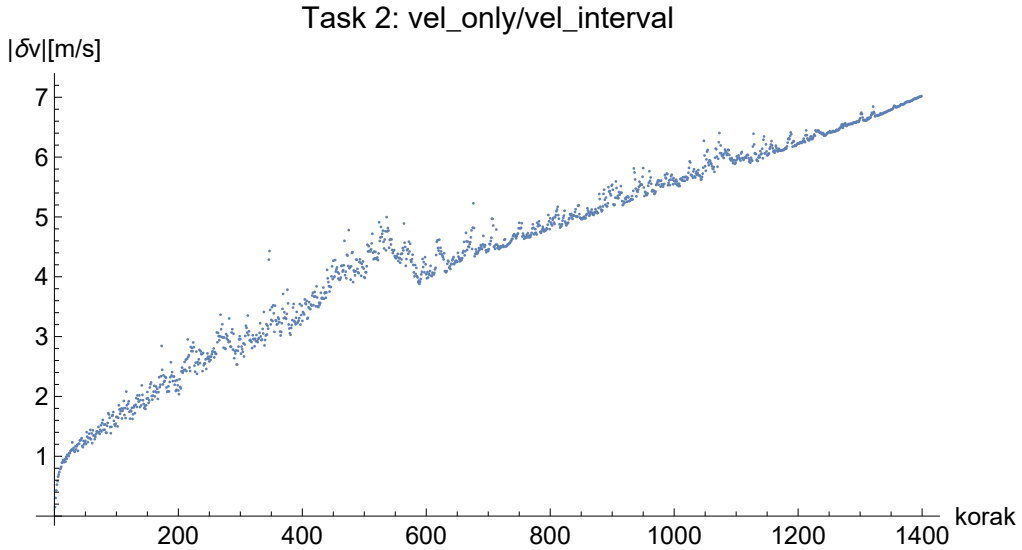

Vpliv vzorčenja lege na odstopanja, če so znane samo hitrosti in pospeški

Spet zašumljena grafa, trend pa naraščanje odstopanj z redčenjem vzorčenja hitrosti.

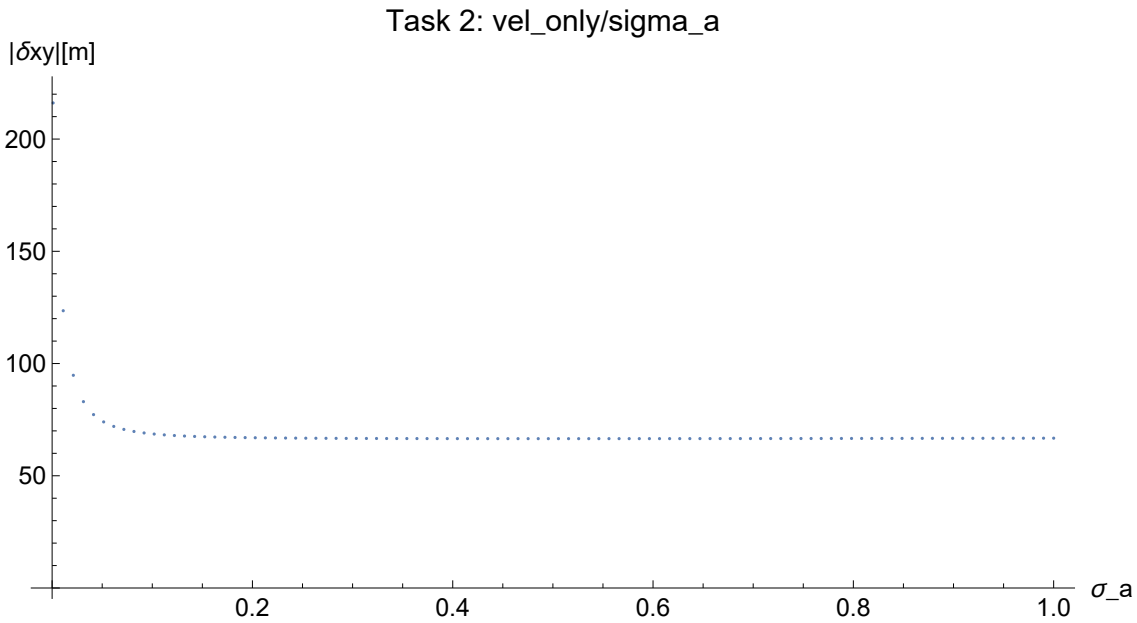

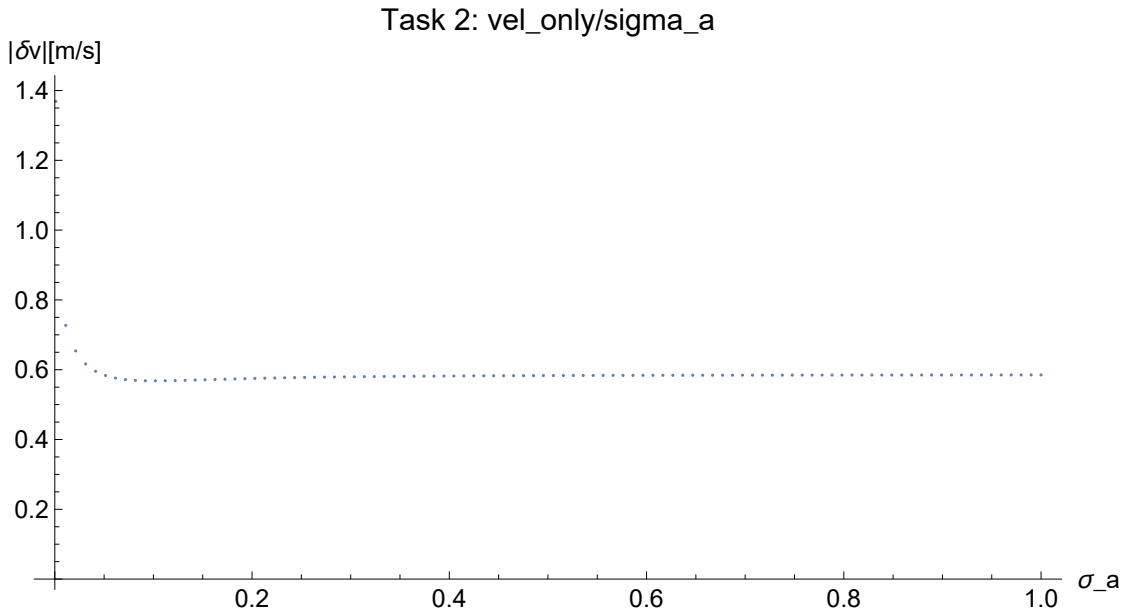

Odstopanji padata z zviševanjem ocene σ_a, hitro dosežeta plato.

Zelo na grobo rečeno, lahko za kvalitativno pravo pot vzamemo le vsakih nekaj deset meritev potem pa se pot hitro oddaljuje od prave. Pri hitrostih in pospeških dobimo malo boljše rezultate, kot pri legah in pospeških.

3.)

V resnici nam akcelerometer podaja pospeške $\boldsymbol{a} = (a_t, a_r)$ glede na trenutno orientacijo vozila.
Med kontrolnim vektorjem in nehomogenim delom dinamičnega modela zato stoji še ena linearna preslikava $B_n : c_n = \boldsymbol{B_n}.\boldsymbol{u_n}$. V tem primeru gre za ortogonalno transformacijo, definirano s
trenutno oceno hitrosti:

$$\mathbf{u}_n = (\mathbf{0}, \mathbf{a}_n \Delta t), \quad B_n = \begin{bmatrix} I_{2\times 2} & 0 \\ 0 & B_n^{vv} \end{bmatrix}, \quad B_n^{vv} = \frac{1}{||\mathbf{v}_n||} \begin{bmatrix} v_x & -v_y \\ v_y & v_x \end{bmatrix}$$

Nekoliko bolj zapletena je potem kovarianca meritve pospeška, saj moramo upoštevati še negotovost trenutne ocene hitrosti:

$$Q_n^{vv} = \Delta t^2 \left\{ \sigma_a^2 I_{2\times 2} + \frac{\mathbf{v}_n^{\perp} P_n^{vv} \mathbf{v}_n^{\perp}}{||\mathbf{v}_n||^4} \left[(B_n^{vv} \mathbf{a}_n^{\perp}) \otimes (B_n^{vv} \mathbf{a}_n^{\perp}) \right] \right\}$$

Pri tem sta $Q_n^{v,v}$ in $P^{v,v}$ hitrostno-hitrostna bloka 4×4 kovariančnih matrik. Vektorja $a_n^{\perp}$ in $v_n^{\perp}$
sta pospešk in hitrost, zavrtena v pozitivni smeri za $\frac{\pi}{2}$. Prvi čen je identičn kot prej, drugi
čen pa upoševa, da projekcija negotovosti hitrosti prečo na smer gibanja pomeni nedoločnost
kota in kvari zanesljivost pospeša. Rekonstruirajmo pot iz podatkov, danih v datoteki kalman_relative_data.-
dat, katere stolpci so čas t, GPS položji (x, y) ter pospeša (at, ar). Spet lahko izbiramo kako pogosto so na voljo
meritve položja.

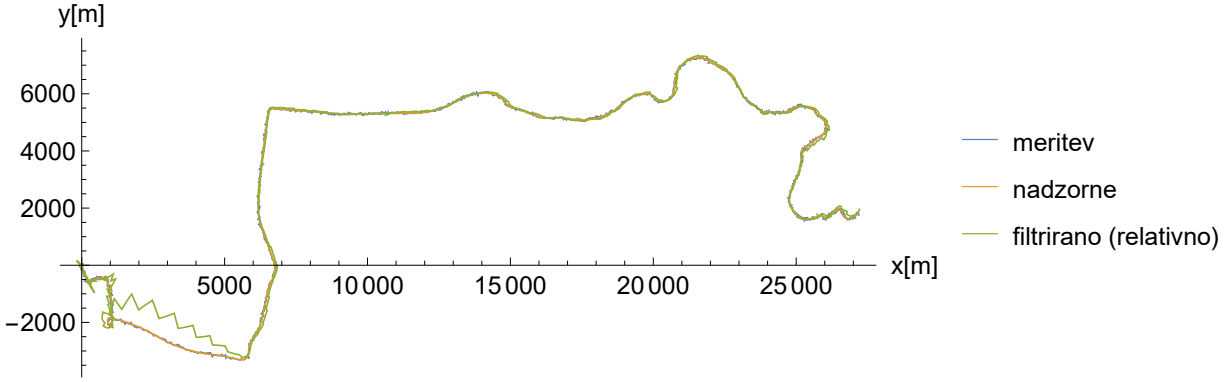

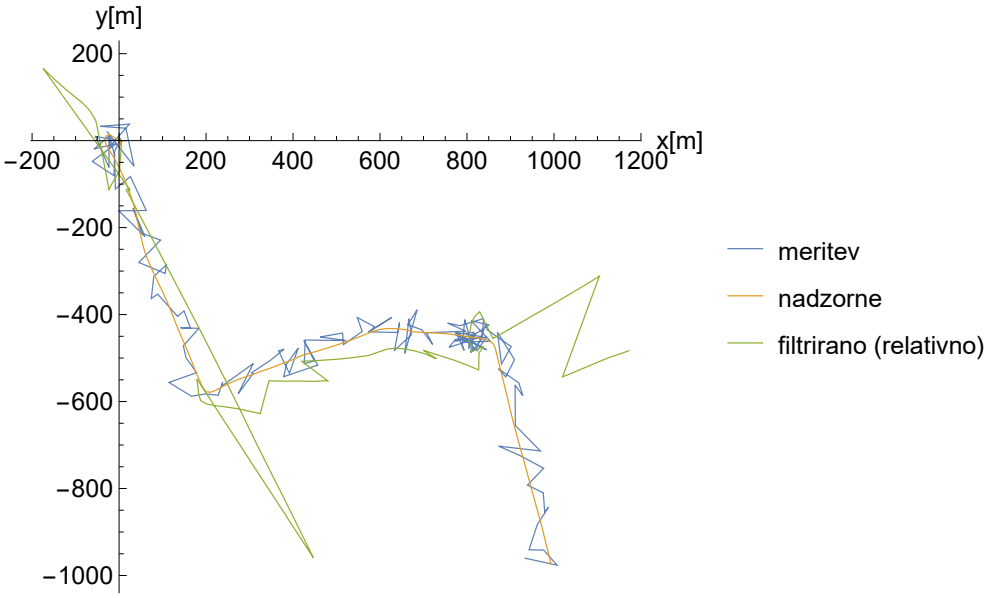

V tem primeru kalmanov filter sprva sploh ne dohaja trajektorije, kasneje pa ji solidno sledi.

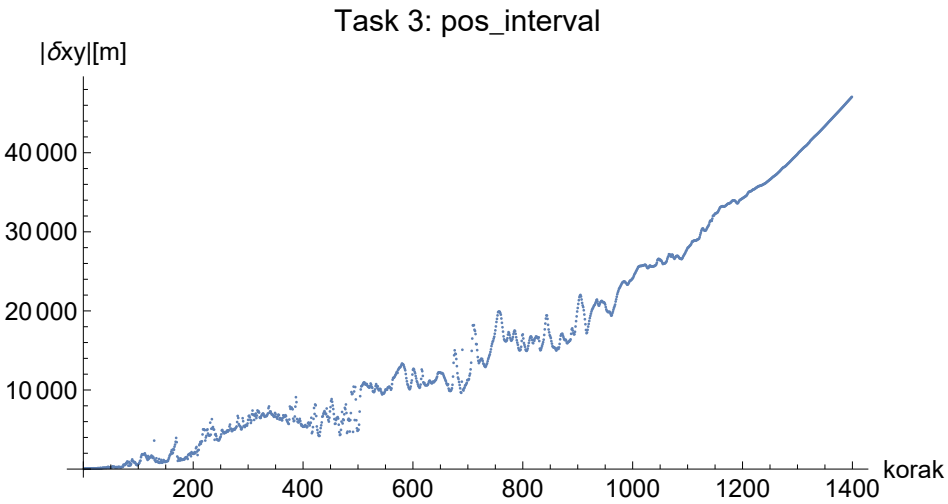

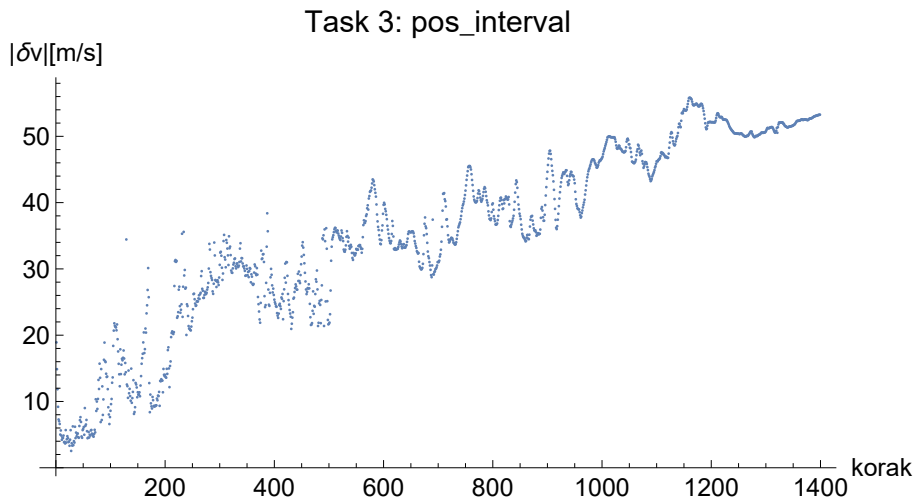

Vidimo, da spet dobimo čisto napačno trajektorijo, če ne vzorčimo na gosto. Za grobo določitev ceste po kateri vozimo, tokrat rabimo vzeti le po 1 na ~200 meritev. Hitrosti pa tudi pri gostem vzorčenju močno odstopajo.

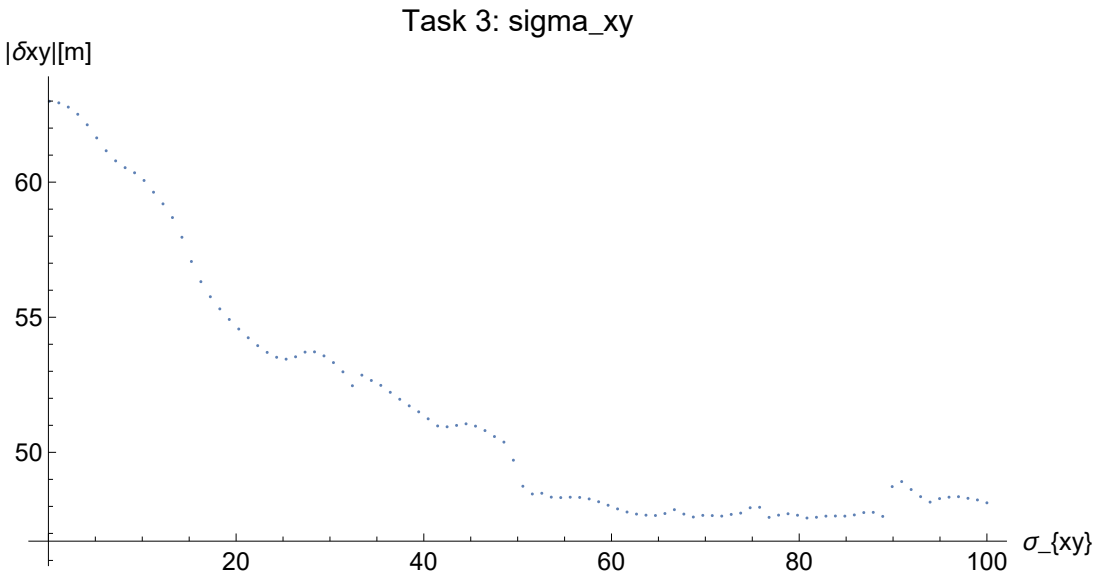

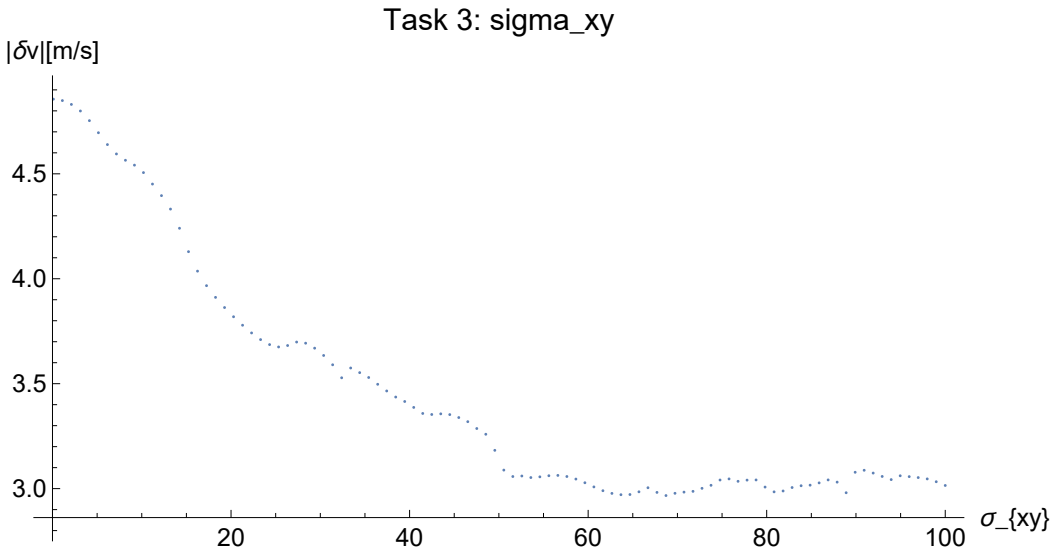

Z večanjem ocene σ_{xy} padajo odstopanja.

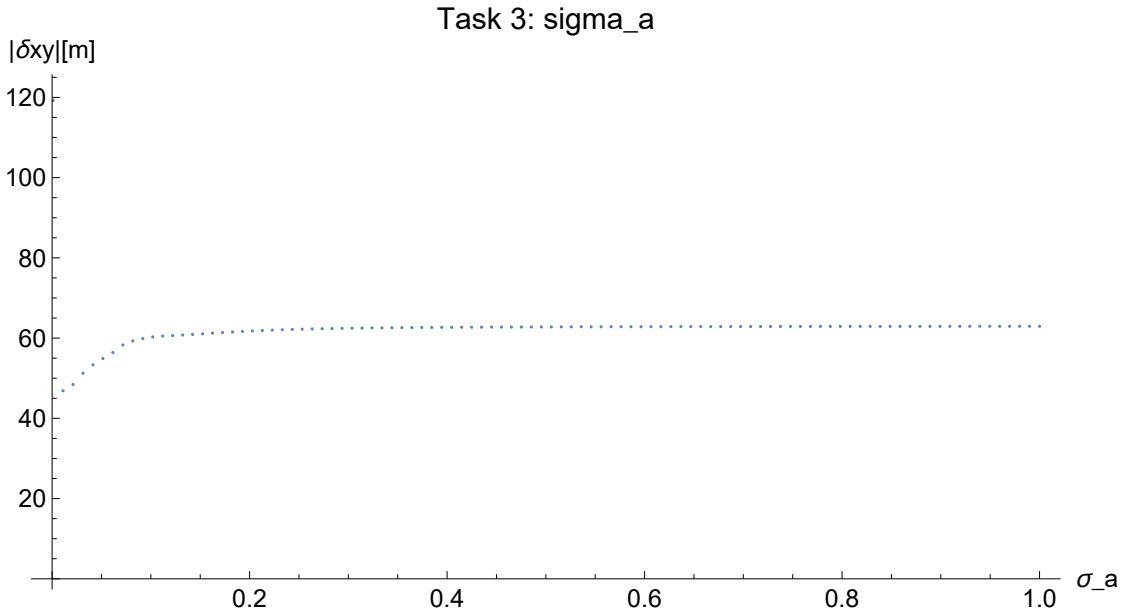
Task 3: sigma_a
|δxy|[m]
120
100
80
60
40
20
0.2
0.4
0.6
0.8
1.0
σ_a

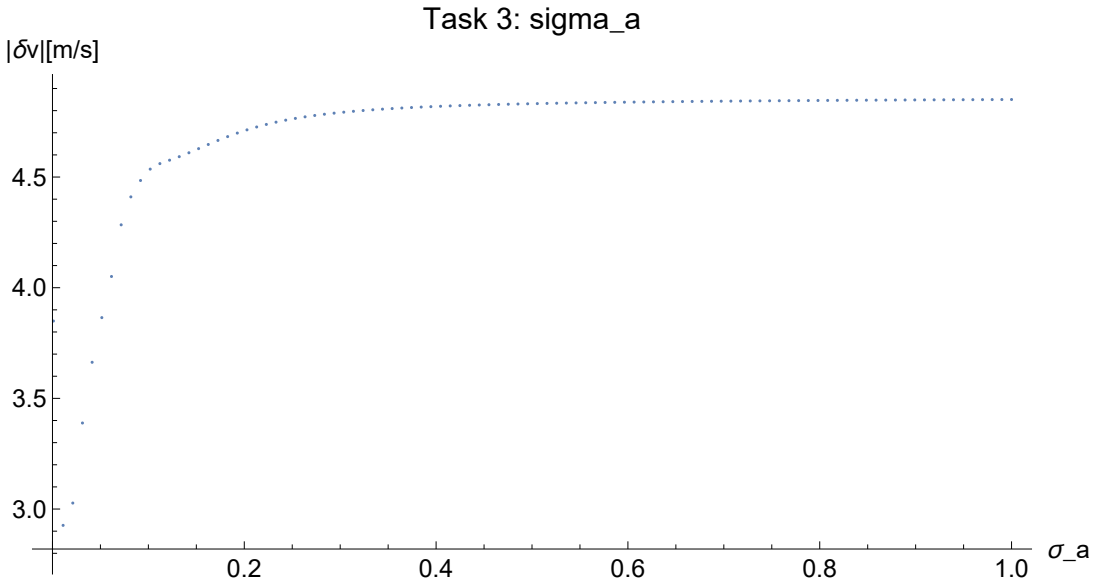
Task 3: sigma_a
|δv|[m/s]
4.5
4.0
3.5
3.0
0.2
0.4
0.6
0.8
1.0
σ_a

3.b) DODATNO: NA KROGLI

Poglejmo še, kakšna je dinamika z relativnimi pospeški, če upoštevamo, da je zemlja orogla. Zamislimo si kolikšen del posamezne komponente hitrosti kaže v smeri poldnevnikov in kolikšen del v smeri vzporednikov. Dobimo dinamiko:

- $\dot{\varphi} = \frac{v_\varphi}{R s_\theta}$
- $\dot{\theta} = \frac{v_\theta}{R}$
- $\dot{v}_\varphi = a_x \frac{v_\varphi}{v} - a_y \frac{v_\theta}{v} = \frac{a_x v_\varphi - a_y v_\theta}{v}$
- $\dot{v}_\theta = a_x \frac{v_\theta}{v} + a_y \frac{v_\varphi}{v} = \frac{a_x v_\theta + a_y v_\varphi}{v}$

vidimo, da dinamika ni linearna, zato bi bilo za ta primer bistveno težje dobiti optimalen filter (ni kalmanov).

Poglejmo kakšno gibanje po 100 m krogli bi dobili z naslednjima pospeškoma:

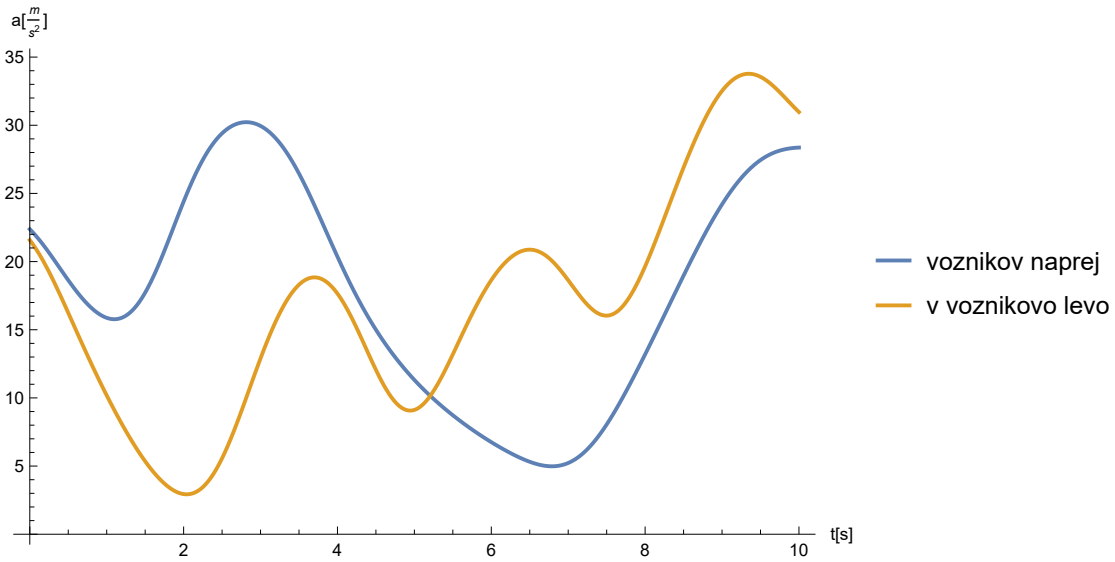

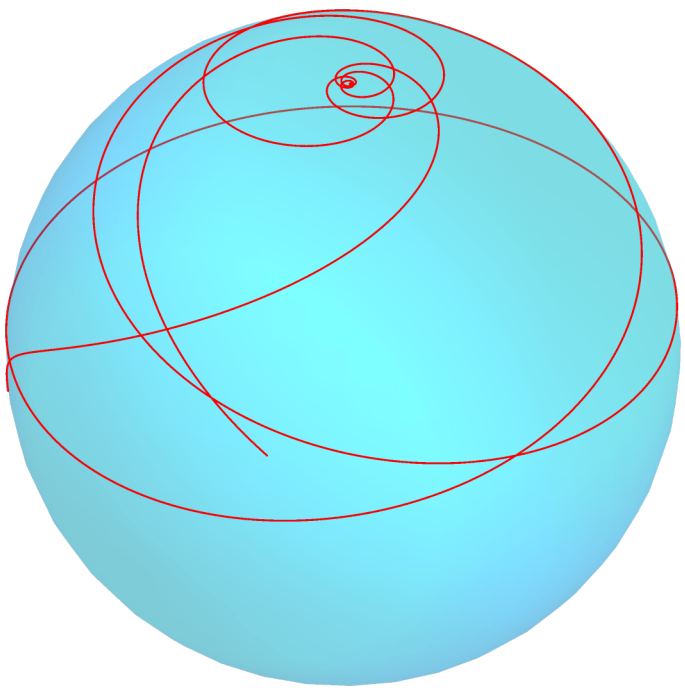

In[ ]:=

```
Quiet@Remove@"Global`*";
{slikaax,slikaay}={ 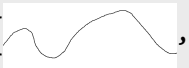 , };
tmax=10.;
NIzmerkov=10000;

iaji[slikaa_]:=1.Mean[Table[If[#[[i]]>.99,i,Nothing],{i,Length@#}]]&/@(1-Map[Total,ImageData[slikaa]^T,{2
                                                                                                  3
iajiji=LowpassFilter[iaji@#,.03]&/@{slikaax,slikaay};
iaodtji={Subdivide[0,tmax,Length@#-1],#}^T&/@iajiji;
tji=Subdivide[0,tmax,NIzmerkov-1];
dt=tji[[2]]-tji[[1]];
iaodtji={tji,Interpolation[#,InterpolationOrder→2]@tji}^T&/@iaodtji;
iaji=iaodtji[[;;,;;,2]]^T;
aji=.1iaji;

ListLinePlot[aji,AspectRatio→Automatic]
R=50;
{θ0,φ0}={π/2.,0};
{vθ0,vφ0}={.3,0};

X0={φ0,θ0,vφ0,vθ0};
X=X0;
KoordInvji=Prepend[X0]@Table[
    v=Norm@X[[3;;]];
    X+={X[[3]]/(R Sin@X[[2]]),X[[4]]/R,(aji[[i,1]]×X[[3]]-aji[[i,2]]×X[[4]])/v,(aji[[i,1]]×X[[4]]+aji[[i,2]]×X[[3]])/v}dt,
{i,Length@tji}];


trajektorija3D=(R{Sin@#2 Cos@#1,Sin@#2 Sin@#1,Cos@#2})&@@@KoordInvji[[;;,;;2]];

Show[
ListLinePlot3D[
    trajektorija3D,
    BoxRatios→Automatic,Boxed→False,Axes→False,
    PlotStyle→{Red,Thickness@.003}
],
Graphics3D@{
    RGBColor@{0,.7,1,.3},
    Sphere[{0,0,0},R]
},
PlotRange→All
]
```

Taka dinamika bi v praksi prišla v upoštev za kake daljše polete. Na krajših razdaljah pa je seveda veliko pomembnejši naklon terena. Če je avto nagnjen, bo imel težni pospešek $\boldsymbol{g}$ neko komponento v pospeškomerovi smeri naprej, in še neko malo komponento vztran. Če bi poznali vektor normale, bi lahko ti komponenti vztrezno odšteli. Recimo, da ceste praktično niso nagnjene vztran. Potem nas zanima le smerni odvod terena v smeri vožnje avta. Tega pa bi se načeloma dalo dobiti iz interpolacije nadmorskih višin. Nisem preveril, ampak verjetno obstaja kaka baza podatkov za nadmorsko višino od koordinat na zemlji.

ZAKLJUČEK

Spoznali smo kalmanv filter, ga uporabili na primeru vožnje in videli, da se stvar z bolj realnimi podatki hitro zaplete.