Modelska analiza I
2024/25

11. naloga – Optimalno filtriranje

Kadar z zaporednimi meritvami spremljamo časovni razvoj procesa, katerega dinamiko poznamo, lahko s filitriranjem dosežemo občutno boljšo natančnost, kot jo dajejo surove meritve. Kalmanov filter deluje na principu optimalnega uteževanja linearne napovedi stanja ter novih meritev, kar doseže s sprotnim vodenjem evidence o kovarianci trenutne ocene stanja.

Naj bo $\mathbf{x}_n$ vektor stanja sistema ob času n, P_n pa pripadajoča kovariančna matrika, ki opisuje njegovo statistično negotovost. Potrebujemo še začetno stanje $\mathbf{x}_0^+$ ter kovarianco P_0^+, ki ju običajno dobimo iz prve surove meritve. Komponentam stanja, ki niso na voljo, nastavimo velike začetne kovariance.

Kalmanov filter poteka v dveh korakih. Prvi korak je izvedba časovnega koraka na trenutni napovedi stanja. Fizikalni sistem naj uboga časovno evolucijo $\mathbf{x}_{n+1} = F_n\mathbf{x}_n + \mathbf{c}_n + \mathbf{w}_n$, kjer je F_n prehodna matrika sistema, $\mathbf{c}_n$ kontrolni vektor, $\mathbf{w}_n$ pa vektor Gaussovega šuma s povprečjem 0 in kovariančno matriko Q_n. Napovemo novo stanje $\mathbf{x}_{n+1}^-$ ter njegovo kovariančno matriko P_{n+1}^-:

$$\begin{aligned}\mathbf{x}_{n+1}^- &= F_n\mathbf{x}_n^+ + \mathbf{c}_n,\\ P_{n+1}^- &= F_nP_n^+F_n^T + Q_n.\end{aligned}$$

Sledi izboljšava te napovedi z novimi meritvami. V splošnem ne merimo neposredno komponent vektorja stanja $\mathbf{x}_n$, temveč neko linearno kombinacijo $\mathbf{z}_n = H_n\mathbf{x}_n + \mathbf{r}_n$, kjer je H_n matrika, ki določa, kaj merimo, $\mathbf{r}_n$ pa šum meritve s kovariančno matriko R_n. Matrika H_n je lahko singularna, če merimo manj spremenljivk, kot je dimenzija sistema.

$$\begin{aligned}K_{n+1} &= P_{n+1}^-H_{n+1}^T(H_{n+1}P_{n+1}^-H_{n+1}^T + R_{n+1})^{-1},\\ \mathbf{x}_{n+1}^+ &= \mathbf{x}_{n+1}^- + K_{n+1}(\mathbf{z}_{n+1} - H_{n+1}\mathbf{x}_{n+1}^-),\\ P_{n+1}^+ &= (I - K_{n+1}H_{n+1})P_{n+1}^-.\end{aligned}$$

Prva enačba določa izboljšanje natančnosti stanja zaradi novih meritev, K_{n+1} je pa *faktor ojačanja*, ki določa, s kolikšno utežjo nova meritev prispeva k popravku.

1. Tipičen primer uporabe Kalmanovega filtra je rekonstrukcija poti in hitrosti vozila na podlagi GPS podatkov o lokaciji, sprotnih podatkov o hitrosti vozila ter pospeškov z akcelerometra. V datoteki `kalman_cartesian_data.dat`[1] so po stolpcih podani čas t, zašumljene meritve položaja (x_n, y_n), hitrosti $(v_{x,n}, v_{y,n})$ ter pospeškov $(a_{x,n}, a_{y,n})$. Eksaktne vrednosti položajev in hitrosti za kontrolo pravilnosti najdete v datoteki `kalman_cartesian_kontrola.dat`. Vse količine so v osnovnih SI enotah.

   V našem primeru je vektor stanja $\mathbf{x} = (x, y, v_x, v_y)$, kontrolni vektor dobimo iz pospeška, $\mathbf{c} = (0, 0, a_x\Delta t, a_y\Delta t)$, prehodna matrika sistema je konstantna in izhaja iz kinematičnih zvez,

   $$F = \begin{bmatrix} I_{2\times2} & I_{2\times2}\Delta t \\ 0 & I_{2\times2}\end{bmatrix},$$

   šum časovne evolucije sledi iz napake pospeška, $Q_n = \mathrm{diag}(0, 0, \sigma_a^2\Delta t^2, \sigma_a^2\Delta t^2)$, šum meritev pa iz napak GPS podatkov ter hitrosti, $R_n = \mathrm{diag}(\sigma_{xy}^2, \sigma_{xy}^2, \sigma_v^2, \sigma_v^2)$.

   Podatki so vzorčeni vsakih $\Delta t = 1.783\,\mathrm{s}$. Za pospeške in GPS podatke sta znani absolutni napaki $\sigma_{xy} = 25\,\mathrm{m}$, $\sigma_a = 0.05\,\mathrm{ms}^{-2}$, za hitrost pa poznamo relativno napako: $\sigma_v = 0.01||\mathbf{v}||$, pri čemer napako vseeno navzdol omejimo na $1\,\mathrm{km/h}$.

   Napovej trajektorijo vožnje ter časovno odvisnost komponent hitrosti, v primeru, da vzorčenje ni tako gosto, kot je podano v datoteki, temveč dobimo le vsako peto meritev hitrosti in vsako

[1] Na voljo na strani `http://predmeti.fmf.uni-lj.si/modelska/podatki`.

deseto meritev lokacije. Katere meritve so na voljo, določate z matriko H_n, ki je v našem primeru vedno diagonalna.

Kovarianca P_n vam pomaga pri določanju intervalov zaupanja za dobljene vrednosti, prav tako je koristno spremljati residuale $||\mathbf{z}_{n+1} - H_{n+1}\mathbf{x}^-_{n+1}||$.

2. S telefonom lahko merimo le lokacijo in pospeške, informacij o hitrostih pa nimamo. Kako dobro lahko določite trajektorijo vožnje in potek hitrosti, če podatki o hitrosti niso na voljo? Kaj pa obratno, če so znane samo hitrosti in pospeški?

3. V resnici nam akcelerometer podaja pospeške $\mathbf{a} = (a_t, a_r)$ glede na trenutno orientacijo vozila. Med kontrolnim vektorjem in nehomogenim delom dinamičnega modela zato stoji še ena linearna preslikava B_n: $\mathbf{c}_n = B_n\mathbf{u}_n$. V tem primeru gre za ortogonalno transformacijo, definirano s trenutno oceno hitrosti:

$$\mathbf{u}_n = (\mathbf{0}, \mathbf{a}_n\Delta t), \quad B_n = \begin{bmatrix} I_{2\times 2} & 0 \\ 0 & B_n^{vv} \end{bmatrix}, \quad B_n^{vv} = \frac{1}{||\mathbf{v}_n||}\begin{bmatrix} v_x & -v_y \\ v_y & v_x \end{bmatrix}$$

Nekoliko bolj zapletena je potem kovarianca meritve pospeška, saj moramo upoštevati še negotovost trenutne ocene hitrosti:

$$Q_n^{vv} = \Delta t^2 \left\{ \sigma_a^2 I_{2\times 2} + \frac{\mathbf{v}_n^\perp P_n^{vv}\mathbf{v}_n^\perp}{||\mathbf{v}_n||^4}\left[(B_n^{vv}\mathbf{a}_n^\perp)\otimes(B_n^{vv}\mathbf{a}_n^\perp)\right]\right\}$$

Pri tem sta Q^{vv} in P^{vv} hitrostno-hitrostna bloka 4×4 kovariančnih matrik. Vektorja $\mathbf{a}_n^\perp$ in $\mathbf{v}_n^\perp$ sta pospešek in hitrost, zavrtena v pozitivni smeri za $\frac{\pi}{2}$. Prvi člen je identičen kot prej, drugi člen pa upošteva, da projekcija negotovosti hitrosti prečno na smer gibanja pomeni nedoločenost kota in kvari zanesljivost pospeška. Če vam ta člen dela težave, ga lahko izpustite.

Rekonstruiraj pot iz podatkov, danih v datoteki `kalman_relative_data.dat`, katere stolpci so čas t, GPS položaji (x, y) ter pospeška (a_t, a_r). Spet lahko izbiraš, kako pogosto so na voljo meritve položaja.